UNIVERSITE HASSAN II DE CASABLANCA

ECOLE NATIONALE SUPERIEURE D'ARTS ET METIER

DEPARTEMENT GENIE INFORMATIQUE

Mémoire de Projet de Fin d'Études
en vue de l'obtention du diplôme du **********

****

Titre :

Mise en place d'un modèle intelligent pour la détection des fraudes dans les assurances médicales

Au sein de la Société :

****

Encadré par :

- ********** : Société ******
- Pr ZAKRANI Abdelali : ENSAM de Casablanca

Soutenu le : 7 / 1 / 2022

Devant le jury composé de :

- ********** : Professeur à ********** de Casablanca
- ZAKRANI Abdelali: Professeur à ********** de Casablanca
- ********** : Professeur à ********** de Casablanca
- ********** : Professeur à ********** de Casablanca

DEDICACES

Je dédie ce projet de fin d'études à mes très chers parents pour leurs sacrifices infinis, affection et amour, leur confiance et patience.

A mes frères et sœurs pour leur encouragement et leur bonté.

Ma chère grande famille pour laquelle j'exprime mes respects les plus sincères.

Mes chers amis, et particulièrement les plus proches.

Mes enseignants, pour leurs efforts qui nous ont permis d'acquérir une formation de qualité.

Tous qui ont collaboré de près ou de loin à l'élaboration de ce travail.

REMERCIEMENT

En préambule, je remercie ALLAH qui m’aide toujours et me donne la patience, le courage et sa bénédiction pour réussir dans toutes mes années d'études.

Ensuite, il est jugé nécessaire d'exprimer mes grands remerciements à tous les responsables de ********* Casablanca surtout aux responsables de la filière Big data et internet des objets pour leurs efforts et leurs aides tout au long de notre formation.

Je tiens également à exprimer mes vifs remerciements et mon hommage profond à mes encadrants Monsieur ZAKRANI ABDELALI et **** ***** pour leurs conseils, leurs orientations et leur collaboration afin d'assurer le bon déroulement de notre projet.

Finalement, j’exprime ma gratitude à toutes les personnes ayant contribuées de près ou de loin à la réalisation de ce travail.

Résumé

Le présent document est la synthèse du travail effectué dans le cadre de notre projet de fin d'études au sein *******).

La détection des fraudes est un domaine de recherche important dans les systèmes de santé du fait de ses conséquences financières provenant principalement des coûts d'investigation, des pertes de revenus et du risque de réputation. Pour atténuer ces conséquences, la plupart des entreprises adoptent des modèles de détection des fraudes basés sur l'apprentissage automatique. Les principaux défis à relever pour construire un modèle efficace de détection des fraudes sont les suivants

- La Manque de données étiquetées : la majorité des données des compagnies d'assurance ne sont pas étiquetées et ne sont pas publiques.
- Le déséquilibre des données : les enregistrements non frauduleux sont beaucoup plus présents que les enregistrements frauduleux.

L'objectif principal de notre projet de fin d'études est le développement d'algorithmes d'apprentissage automatique qui aident les experts en assurance à lutter efficacement contre la fraude. Notre travail couvre l'ensemble du pipeline d'un projet de science des données, depuis la préparation et l'étiquetage des données jusqu'à l'évaluation des modèles et l'interprétation des résultats.

Les données ont été collectées et étiquetées conformément aux travaux effectués dans l'état de l'art, puis, les données ont été nettoyées et préparées pour le processus de formation. Random Forest, XGBoost et le réseau de neurones sont choisis comme algorithmes prédictifs pour ce projet en raison de leur haute performance par rapport à d'autres méthodes. De nombreuses techniques d'échantillonnage ont été testées afin de réduire l'effet du déséquilibre des données.

Comme il est plus important de détecter le maximum de cas frauduleux, le rappel est la métrique sur laquelle l'évaluation est basée, le sous-échantillonnage aléatoire a donné le meilleur score pour les trois algorithmes, cependant la précision du modèle reste très faible, ce qui est principalement dû à la qualité des données et au déséquilibre des classes.

Mots-clés : détection de la fraude, déséquilibre des classes, échantillonnage aléatoire, apprentissage automatique, Medicare, assurance maladie.

Abstract

This report is a summary of the work done as part of our end-of-studies project at **********.

Due to the financial impacts of fraud, which include costs associated with investigations, lost revenue, and adverse publicity, fraud detection is a crucial field of

research in health systems. The majority of businesses are implementing machine learning-based fraud detection models to reduce these effects. The key difficulties in creating a reliable fraud detection model are.

- Lack of labeled data: The majority of data from insurance companies is unlabelled and private.
- Data imbalance: There are much more non-fraudulent records than fraudulent records.

Our project's main goal is to build machine learning algorithms that will assist insurance adjusters in efficiently fighting against fraud. From data preparation and labelling to model evaluation and results interpretation, our work covers the full data science project lifecycle.

The data was collected and labelled according to the work done in the state of the art, and then, the data was cleaned and prepared for the training process. Random Forest, XGBoost and neural network are chosen as predictive algorithms for this project due to their high performance compared to other methods. Many sampling techniques were tested to reduce the effect of data imbalance.

Since it is more important to detect the maximum number of fraudulent cases, the recall score is the metric on which we based our evaluation, the random subsampling gave the best score for all three algorithms, however the accuracy of the model is still very low, which is mainly due to the data quality and class imbalance.

Keywords: fraud detection, class imbalance, random sampling, machine learning, Medicare, health insurance.

Table des matières

Introduction générale 1
1 Présentation du projet 2
1.1 Introduction 2
1.2 Organisme d'accueil 2
1.2.1 Présentation 2
1.2.2 Vision 3
1.2.3 Mission 3
1.2.4 Pôles et centres de recherche 4
1.2.5 Partenariats et collaborations 5
1.3 Contexte générale du projet 6
1.3.1 Problématique 6
1.3.2 Objectif 6
1.3.3 Planification du projet 7
1.4 Conclusion 7
2 Etat de l'art 8
2.1 Introduction 8
2.2 Revue de littérature 8
2.3 Etude théorique 10
2.3.1 Déséquilibre des données 10
A. Sous-échantillonnage aléatoire 10
B. Sur-échantillonnage aléatoire 11
2.3.2 Algorithmes d'apprentissage 12
A. Random forest 12
B. XGBoost 16
C. Réseaux de neurones 20
a. Perceptron monocouche 20
b. Perceptron multicouche 21
2.4 Conclusion 24

3 Bases des données 25
3.1 Introduction 25
3.2 CMS Medicare Part B 25
3.3 LEIE data 27
3.4 Annotation des donnés 29
3.5 Base de données finale 29
3.6 Conclusion 31
4 Méthodologie 32
4.1 Introduction 32
4.2 Cycle OSEMN 32
4.3 Outils de développement 33
4.4 Nettoyage des données 34
4.5 Exploration des données 35
4.5.1 Taux de fraude 35
4.5.2 Analyse univarié 37
A. Variables numériques 37
a. Boite à moustaches 37
b. Histogramme 40
B. Variables catégorielles 41
a. Distribution du sexe 42
b. Distribution des années 43
c. Distribution des spécialités et des états 43
4.5.3 Analyse bivarié 44
A. Taux de fraude par sexe 45
B. Taux de fraude par année 45
C. Taux de fraude par spécialité et état 46
D. Corrélation 47
4.6 Conclusion 48
5 Modélisation et résultats 49
5.1 Introduction 49
5.2 Prétraitement 49
5.2.1 Conversion des variables catégorielles 49
5.2.2 Répartition des données 50

5.3 Validation croisée 50
5.4 Métriques d'évaluation 52
5.4.1 Matrice de confusion 52
5.4.2 Evaluation des modèles 53
5.5 Résultats et discussion 53
5.5.1 Déséquilibre des données 53
5.5.2 Random Forest 54
A. Modèle de base 54
B. Sous-échantillonnage aléatoire 55
C. Sur-échantillonnage aléatoire 55
D. Combinaison des deux 56
5.5.3 XGBoost 56
A. Modèle de base 56
B. Sous-échantillonnage aléatoire 57
C. Sur-échantillonnage aléatoire 57
D. Combinaison des deux 57
5.5.4 Réseaux de neurones 58
A. Modèle de base 58
B. Sous-échantillonnage aléatoire 58
C. Sur-échantillonnage aléatoire 59
D. Combinaison des deux 59
5.5.5 Evaluation finale 60
A. Random Forest 60
B. XGBoost 61
C. Réseaux de neurones 62
5.6 Conclusion 64
Conclusion générale et perspectives 65
Bibliographie 66

Liste des figures

Figure 1 : Partenaires de MASciR 5
Figure 2 : Diagramme de Gantt 7
Figure 3 : Sous-échantillonnage 11
Figure 4 : Sur-échantillonnage 11
Figure 5 : Apprentissage ensembliste 13
Figure 6 : Arbre de décision 13
Figure 7 : Exemple d'un arbre de décision 15
Figure 8 : Random Forest 16
Figure 9 : Algorithme de Boosting 17
Figure 10 : Exemple d'une fonction de coût 18
Figure 11 : Gradient descent 18
Figure 12 : XGBoost 19
Figure 13 : Perceptron monocouche 20
Figure 14 : Sortie d'un perceptron 20
Figure 15 : Perceptron multicouche 21
Figure 16 : Forward propagation 22
Figure 17 : Rétropropagation 23
Figure 18 : Echantillon données Medicare 26
Figure 19 : Echantillon données LEIE 27
Figure 20 : Règles LEIE relatives à la fraude 28
Figure 21 : Taux de fraude 31
Figure 22 : OSEMN Framework 33
Figure 23 : Taux de fraude après échantillonnage 37
Figure 24 : Boite à moustaches 38
Figure 25 : Boites à moustaches des variables numériques 38
Figure 26 : Effet des valeurs aberrantes 40
Figure 27 : Distribution des variables numériques 41
Figure 28 : Sexe des praticiens 42
Figure 29 : Distribution des années 43

Figure 30 : Taux de fraude par sexe 45
Figure 31 : Taux de fraude par année 46
Figure 32 : Corrélation des variables 47
Figure 33 : One-hot encoding 49
Figure 34 : Validation croisée 51
Figure 35 : Matrice de confusion 52
Figure 36 : Matrice de confusion Random Forest 61
Figure 37 : Matrice de confusion XGBoost 62

Liste des tableaux

Tableau 1 : Fiche technique de MASciR 3
Tableau 2 : Liste des attributs 31
Tableau 3 : Pourcentage des valeurs nulles 34
Tableau 4 : Pourcentage des valeurs aberrantes 39
Tableau 5 : Spécialités les plus fréquentes 44
Tableau 6 : Etats les plus fréquents 44
Tableau 7 : Spécialités les plus frauduleuses 46
Tableau 8 : Etats les plus frauduleux 47
Tableau 9 : Train-Test split 50
Tableau 10 : Random Forest (Modèle de base) 54
Tableau 11 : Random Forest (Sous-échantillonnage aléatoire) 55
Tableau 12 : Random Forest (Sur-échantillonnage aléatoire) 55
Tableau 13 : Random Forest (Sur/Sous échantillonnage) 56
Tableau 14 : XGBoost (Modèle de base) 56
Tableau 15 : XGBoost (Sous-échantillonnage aléatoire) 57
Tableau 16 : XGBoost (Sur-échantillonnage aléatoire) 57
Tableau 17 : XGBoost (Sur/Sous échantillonnage) 58
Tableau 18 : Réseaux de neurones (Modèle de base) 58
Tableau 19 : Réseau de neurones (Sous-échantillonnage aléatoire) 59
Tableau 20 : Réseau de neurones (Sur-échantillonnage aléatoire) 59
Tableau 21 : Réseau de neurones (Sur/Sous échantillonnage) 59
Tableau 22 : Résultats sous-échantillonnage 60
Tableau 23 : Random forest optimisé 61
Tableau 24 : XGBoost optimisé 62
Tableau 25 : Réseau de neurones optimisé 63
Tableau 26 : Matrice de confusion réseaux de neurones 63
Tableau 27 : Performances des algorithmes optimisés 64

Introduction générale

Qu'est-ce que **l'intelligence artificielle** ? Il s'agit de la science et l'ingénierie de la conception et développement de systèmes intelligents, en particulier de programmes informatiques intelligents, d'après le Pioneer de l'intelligence artificielle, John McCarthy, l'intelligence artificielle peut être définie comme l'ensemble des techniques et procédés mis en œuvre pour générer une entité intelligente. Cette intelligence doit avoisiner celle humaine, voire la surpasser. C'est tout type de technologie capable d'agir à la manière de l'homme.

L'une des applications les plus répondues de l'intelligence artificielle est **la détection de fraude**, dans le domaine des technologies de l'information, les activités frauduleuses ont eu lieu dans de nombreux secteurs tels que les réseaux de télécommunication, les assurances, la banque en ligne et le commerce électronique.

Le taux fraude augmente considérablement avec la transformation digitale de nombreux services, pour cela il s'avère indispensable de développer des systèmes intelligents pour la détection automatique des fraudes, surtout dans les secteurs vitaux comme **l'assurance maladie** où le taux de fraude connaît une augmentation alarmante, c'est dans ce cadre que s'inscrit mon sujet de projet de fin d'études qui consiste à aider les experts assurance maladie à identifier les acteurs frauduleux à travers les méthodes d'intelligence artificielle.

Pour atteindre cet objectif, le rapport de mon travail s'articulera autour de six chapitres. Le premier définit le contexte général du projet en présentant l'entreprise d'accueil et en donnant une vue globale sur le projet. Le deuxième chapitre est consacré à la revue de littérature et l'explication théorique des différentes techniques de détection de fraude dans un contexte assurance maladie. Les détails concernant la collecte et la préparation de la base de données sont présentés par la suite dans le troisième chapitre. Le quatrième chapitre décrit en détails la méthodologie suivie pendant la réalisation de notre projet. Les différents résultats et leurs interprétations sont présentés dans le cinquième et dernier chapitre.

1 Présentation du projet

1.1 Introduction

L'objectif de ce chapitre est la présentation du contexte générale du projet. Dans un premier lieu, nous donnerons un aperçu général sur l'organisme d'accueil ensuite nous présenterons une vision globale du projet.

1.2 Organisme d'accueil

1.2.1 Présentation

La ******** [1] est une association à but non lucratif qui relève de l'Université Mohammed VI Polytechnique. Créée en 2007, elle vise la promotion et le développement de pôles de recherche technologique dans les domaines des matériaux et nanomatériaux, de la biotechnologie, de la microélectronique et des sciences de la vie. Ses travaux sont orientés vers la recherche appliquée et l'innovation pour répondre aux besoins du marché [2].

****** dispose de plateformes scientifiques à la pointe de la technologie et d'un capital humain de haut niveau. Ses chercheurs opèrent dans différents champs innovants et complémentaires. Des mines aux énergies renouvelables, en passant par la santé et le transport, les recherches menées à ***** se focalisent sur les besoins actuels et futurs de l'industrie, de l'agriculture et des opérateurs économiques en général.

Raison sociale	********
Date de création	2007
Siège social	Rue Mohamed El Jazouli, Rabat Design Center, Madinat Al Irfane, 10100 Rabat, Maroc
Forme juridique	Institution publique à but non lucratif
Directrice générale	Mme. Nawal CHRAIBI
Effectif globale	+150 Ingénieurs et Chercheurs
Téléphone/Fax	+212 530279875/ +212 530275828
Site web	www.******.com

*Tableau 1 : Fiche technique de ****

1.2.2 Vision

La Fondation ***** vise la valorisation des résultats de sa recherche et ses brevets d'inventions [2], à travers le transfert de technologie, la création de spin-off et start-up afin de contribuer à l'émergence au Maroc d'une économie du savoir. Elle vise l'excellence scientifique et technologique grâce à :

- Une plateforme dotée d'équipements à la pointe de la technologie ;
- Des collaborateurs reconnus dans leurs domaines d'expertises ;
- Des partenariats académiques et industriels à l'échelle internationale ;
- Une production scientifique de haut niveau.

1.2.3 Mission

La Fondation a pour objet de promouvoir et de développer au Maroc des pôles de recherche et de développement technologique répondant aux besoins du marché dans les secteurs de la nanotechnologie, la biotechnologie, la technologie numérique, la microélectronique, les sciences de la vie et de toute autre technologie avancée. [2]

À cet effet ****** a pour missions de :

- Servir en tant que support de développement pour les secteurs technologiques avancés cités ci-dessus ;
- Promouvoir le développement de ressources humaines et de compétences de standard international dans ces secteurs ;
- Mener la recherche appliquée et le développement d'applications technologiques dans le but de générer de la propriété intellectuelle et industrielle dans ces secteurs et ce en adéquation avec les besoins du marché dans ces domaines ;
- Conclure des partenariats et servir de lien entre l'industrie et les structures académiques ;
- Favoriser l'émergence d'entreprises innovantes à partir des développements technologiques réalisés ;
- Contribuer à la formation de compétences hautement qualifiées dans les domaines relatifs à son objet et/ou ses missions.

1.2.4 Pôles et centres de recherche

La fondation **** comporte trois pôles de recherche principaux :

- **Pôle biotechnologie** qui contient deux centres ; **« Biotechnologie médicale »** qui a pour but le développement de kits pour le dépistage et le diagnostic de certains types de cancers, de maladies auto-immunes et de maladies infectieuses et la mise en place d'une plateforme technologique pour la production des biosimilaires. Le centre de **« Biotechnologie végétale »** qui mène des projets orientés marché portant sur la biotechnologie des microalgues et l'Agro-biotechnologie.
- **Pôle microélectronique** dont le centre **« Digitalization et Microelectronics Smart Devices »** qui porte principalement sur le développement de capteurs spécifiques opérant notamment dans un environnement agressif. Et le centre

« Systèmes Embarqués et Intelligence Artificielle » qui réalise des travaux de recherche et développement pour des industriels autour de la gestion de trafic, de l'inspection visuelle et du développement de systèmes de santé.

- **Pôle matériaux et nanomatériaux** qui contient cinq centres ; Le centre **« Durabilité et Ingénierie des matériaux »** qui a pour principale mission l'évaluation de la durabilité des matériaux dans leur milieu de fonctionnement réel. Le centre **« Composites et Nano-composites »** développe des thèmes de recherche pluridisciplinaires relatifs à la fabrication, le processing et le prototypage des composites, nano-composites et bio composites, pour des applications dans différents secteurs industriels. Le centre **« Optique Photonique »** qui réalise des travaux de recherche et développement autour des énergies renouvelables, des nanomatériaux, et des systèmes biophotoniques pour la santé. Le Centre **« Valorisation des Ressources Naturelles (VARENA) »** développe des projets dans les thématiques de recherche en relation avec les besoins du Maroc dans les domaines des matériaux, de l'environnement, de l'énergie et de la durabilité. Le centre **« Matériaux et Nanomatériaux »** réalise des projets de Recherche et Développement orientés marché en s'appuyant sur son expertise en physique et chimie des matériaux, et en particulier dans le domaine des nanomatériaux et nanotechnologies.

1.2.5 Partenariats et collaborations

La Fondation **** est un centre de recherche qui a pour vocation de mettre la R&D au service de l'économie nationale et de contribuer au rayonnement scientifique du Maroc à l'international [3]. La Fondation **** a noué avec son environnement industriel, institutionnel et académique des relations fortes axées sur la recherche, l'expertise et la mutualisation des moyens.

Au niveau international, la Fondation ****** participe au rayonnement scientifique du Maroc à travers la réalisation de projets R&D dans le cadre de partenariats avec des institutions de recherche et/ou des entreprises.



*Figure 1 : Partenaires de ******

1.3

Contexte général du projet

1.3.1 Problématique

L'un des problèmes les plus importants du secteur de l'assurance maladie est la fraude, qui entraîne des pertes substantielles pour les gouvernements et les compagnies d'assurance. Selon *Insurance Europe*, la fraude détectée et non détectée coûterait aux clients et aux assureurs européens environ 13 milliards d'euros par an [4], en France, les activités frauduleuses ont coûté 261,2 millions d'euros en 2018, principalement à cause des praticiens (opticiens, pharmaciens, auxiliaires médicaux, médecins, etc.) et des institutions [5], Aux États-Unis, *National Heath Care Anti-Fraud Association* estime que la fraude dans le domaine de la santé coûte à la nation environ 68 milliards de dollars par an, soit environ 3% des 2.26 trillions de dollars de dépenses de santé du pays. D'autres estimations vont jusqu'à 10% des dépenses annuelles de santé, soit 230 milliards de dollars [6].

Au niveau national, le directeur exécutif des prestations de *RMA Watanya* rapporte que 10% de cas de fraude est la norme observée mondialement et estime qu'au Maroc le secteur est légèrement au-delà [7].

La plupart des compagnies d'assurance disposent de systèmes de détection des fraudes basés sur des règles métier, ces méthodes, bien qu'efficaces, sont souvent très difficiles à mettre en place et à maintenir.

Grâce aux progrès réalisés dans le domaine de la science des données et à la numérisation de nombreux services d'assurance, il est désormais possible de lutter plus efficacement contre la fraude, en développant des modèles intelligents capables de détecter les activités frauduleuses.

Dans ce sens, le sujet de stage proposé par l'entreprise est : Le développement des modèles d'intelligence artificielle pour la détection de fraude dans les dossiers d'assurance maladie.

1.3.2 Objectif

L'objectif principal de ce projet est de développer des modèles intelligents en se basant sur les algorithmes et les techniques d'apprentissage automatique qui viendraient aider les experts assurances à détecter d'une manière efficace les activités frauduleuses présentes dans le secteur assurance maladie.

Afin d'atteindre l'objectif souhaité, mon encadrante m'a confiée les missions suivantes :

- Réalisation d'**un état de l'art** sur les techniques et modèles employés pour la détection de fraude dans le contexte de l'assurance maladie ;
- **Collecte et préparation** de la base de données ;
- **Nettoyage, exploration et visualisation** des données ;
- **Développement, entraînement et évaluation** de modèles d'apprentissage
- **Interprétation** des résultats.

1.3.3 Planification du projet

Parmi les différentes phases d'un projet, la planification est sans aucun doute l'une des plus importantes. Elle consiste à déterminer la liste des tâches à réaliser, à estimer le coût d'exécution de chaque tâche et à choisir les profils et les ressources nécessaires et les ressources à prévoir. La planification permettra d'assurer le suivi du projet pendant son élaboration, il sera ainsi possible de déterminer si les objectifs fixés sont atteints dans les délais prévus, ainsi, un planning prévisionnel est nécessaire pour la bonne gestion du projet.

Afin de mettre le plan des différentes tâches à réaliser, nous avons choisi le **diagramme de Gantt** [8] qui est l'un des outils les plus efficaces qui permettent de représenter chronologiquement les opérations à effectuer dans le cadre de la réalisation d'un projet. La figure suivante présente le diagramme résultant :

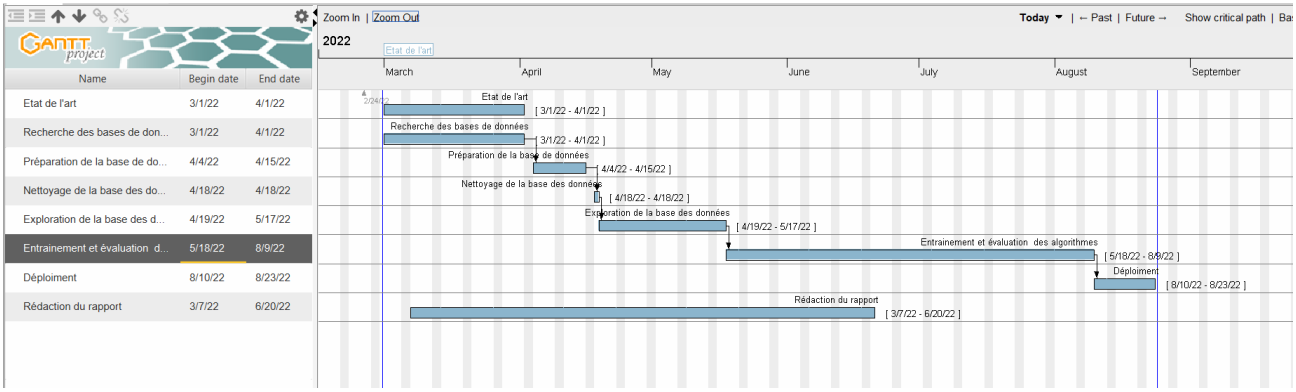


Figure 2 : Diagramme de Gantt

1.4 Conclusion

Ce chapitre introductif a été le point de départ pour l'élaboration de notre projet de fin d'études. Nous avons présenté l'organisme d'accueil, ses missions, ses valeurs ainsi que ses différents départements et partenaires, ensuite nous avons exposé le contexte général du projet à travers la problématique, l'objectif et la planification du projet.

2 Etat de l'art

2.1 Introduction

Le but de ce troisième chapitre est de présenter les différentes techniques et résultats obtenus des études décrivant l'analyse et la détection d'activités frauduleuses dans le secteur d'assurance maladie. Il s'agit d'une revue de littérature approfondie ainsi qu'une étude théorique des différents algorithmes.

2.2 Revue de littérature

Aujourd'hui, de nombreuses agences d'assurance maladie utilisent les derniers outils d'apprentissage automatique et d'exploration de données pour élaborer des modèles de détection de la fraude. Un modèle de détection des fraudes efficace peut identifier des motifs cachés dans les données qui ne seraient pas évidents autrement. Il s'agit d'un problème de classification supervisé, dont le but est de prédire le label d'un ensemble des données d'entrée, pour notre cas, le label sera : fraude ou non-fraude. Cependant l'un des défis majeurs rencontré lors du développement d'un modèle de détection de fraude est le déséquilibre des données, puisqu'en réalité, la majorité des demandes traitées par la compagnie d'assurances sont des demandes légitimes.

Les systèmes basés sur des règles métier sont utilisés dans divers secteurs, ils se basent sur un ensemble de règles prédéfinies [9]. Ils sont mis en œuvre pour identifier les erreurs, les données incomplètes, les demandes en double, les demandes inéligibles, les demandes suspectes, etc. Ces systèmes peuvent ne pas avoir la capacité de modéliser un comportement frauduleux. Dans un contexte assurance maladies, des modèles de détection de fraude plus sophistiqués sont basés sur l'exploration de données et l'apprentissage automatique [10].

Bauder et Khoshgoftaar (2016) ont développé une nouvelle technique pour détecter les activités frauduleuses chez les praticiens, ils ont ajusté plusieurs modèles de régression multivariés aux données des provenant de *Centers for Medicare & Medicaid Services* (CMS) [11]. Les auteurs calculent ensuite un vecteur de paiements attendus pour le praticien, en utilisant les modèles de régression, ils calculent ensuite les erreurs, ou résidus, que les modèles produisent, en utilisant les vecteurs réels et attendus des paiements, en utilisant les vecteurs de paiements réels et attendus. Lorsque les résidus calculés pour un praticien sont élevés, ils le traitent comme un indicateur d'activité frauduleuse [12].

Fursov et al. (2017) proposent des architectures d'apprentissage profond (*Deep Learning*) qui traitent des données d'assurance composées de variables séquentielles des visites et des variables tabulaires des patients, les composantes séquentielles et tabulaires améliorent la qualité du modèle, générant de nouvelles perspectives dans la détection de la fraude à l'assurance maladie. Les résultats obtenus à partir des données d'une compagnie anonyme d'assurance maladie montrent que l'approche proposée surpasse les modèles d'apprentissage classiques et peut améliorer considérablement le processus de gestion des sinistres. Pour mesurer les

performances du modèle, les auteurs ont choisi la courbe ROC [13], ils ont obtenu un score de 0,873 [14].

Bauder et al. (2018) ont présenté une étude qui évalue cinq méthodes d'apprentissage automatique non supervisées dans la détection de la fraude chez les praticiens en utilisant les données CMS, afin de valider la performance de chaque méthode, ils ont utilisé la base de données *List of Excluded Individuals/Entities* (LEIE) [15] qui contient des informations sur les praticiens exclus, l'algorithme local outlier factor (LOF) [16] a donné la meilleure performance globale de détection de la fraude avec un score de 0.630 ROC AUC. Les auteurs ont constaté que les scores AUC de toutes les méthodes non supervisées sont relativement faibles [17].

Dans [18], Khoshgoftaar et Bauder (2018) testent la capacité de Random Forest [19] à détecter des comportements anormaux dans des données CMS avec différents ratios de déséquilibre de classe. Ils contrôlent le déséquilibre des classes en utilisant la technique de sous échantillonnage aléatoire [20], les auteurs rapportent la meilleure performance de Random Forest avec une valeur AUC moyenne de 0,87302 et une distribution de classe de 90% d'instances non frauduleuses à 10% d'instances frauduleuses.

Johnson et Khoshgoftaar (2019) étudient les performances des algorithmes d'apprentissage profond sur la tâche de détection de la fraude dans les données CMS, les chercheurs ont testé plusieurs techniques d'échantillonnage, tout en faisant varier le seuil de classification, les résultats montrent que le seuil de décision par défaut de 0,5 n'est jamais optimal lorsque les données de d'entrainement sont déséquilibrées, et le seuil doit toujours être optimisé lorsque les classes sont déséquilibrées, de plus, l'apprentissage profond avec une combinaison de sous-échantillonnage et de sur-échantillonnage aléatoires est la méthode préférée pour détecter la fraude dans les données CMS avec un score ROC de 0.8505 [21].

Gupta et al. (2021) ont utilisé trois techniques différentes de déséquilibre des données et six modèles de classification, et ils ont également utilisé six variantes de modèles de réseaux de neurones. Au total, 26 modèles ont été testés dans le cadre de cette étude. Les performances de ces modèles ont été mesurées à l'aide de diverses métriques telles que la précision, la sensibilité, la spécificité et le score F1. Il a été identifié qu'un modèle de réseau de neurones formé sur des données sous échantillonnées a donné de meilleurs résultats que les autres modèles de cette étude [22].

2.3 Etude théorique

2.3.1 Déséquilibre des données

La classification déséquilibrée est un exemple de problème de classification où la distribution des exemples dans les classes connues est biaisée ou asymétrique. La distribution peut varier d'un léger biais à un grave déséquilibre où il y a un seul exemple dans la classe minoritaire pour des centaines, des milliers ou des millions d'exemples dans la ou les classes majoritaires.

Le déséquilibre des données pose un défi dans le cas de classification, car la plupart des algorithmes d'apprentissage automatique utilisés pour la classification ont été conçus en se basant sur l'hypothèse d'un nombre égal d'exemples pour chaque classe. Il en résulte des modèles dont les performances prédictives sont faibles, en particulier pour la classe des minorités, c'est un problème car, en général, la classe des minorités est plus importante comme dans le cas de détection des fraudes.

Il existe plusieurs techniques pour résoudre le problème du déséquilibre des données, dans le contexte de la détection de la fraude à l'assurance maladie, de nombreux chercheurs utilisent des techniques d'échantillonnage, à savoir, le sous-échantillonnage aléatoire, le sur-échantillonnage aléatoire et la combinaison des deux [18] [21] [23] [22].

A. Sous-échantillonnage aléatoire

Le sous-échantillonnage aléatoire consiste à sélectionner aléatoirement des exemples de la classe majoritaire et à les supprimer de l'ensemble de données d'apprentissage. Dans le sous-échantillonnage aléatoire, les instances de la classe majoritaire sont éliminées au hasard jusqu'à ce qu'une distribution plus équilibrée soit atteinte.

L'utilisation de cette approche est efficace dans les situations où la classe minoritaire dispose d'un nombre suffisant d'exemples malgré le déséquilibre, la plus grande limitation de cette technique est que les exemples de la classe majoritaire sont supprimés aléatoirement, alors qu'ils peuvent être utiles, importants ou peut-être critiques pour ajuster un modèle de classification robuste [24].

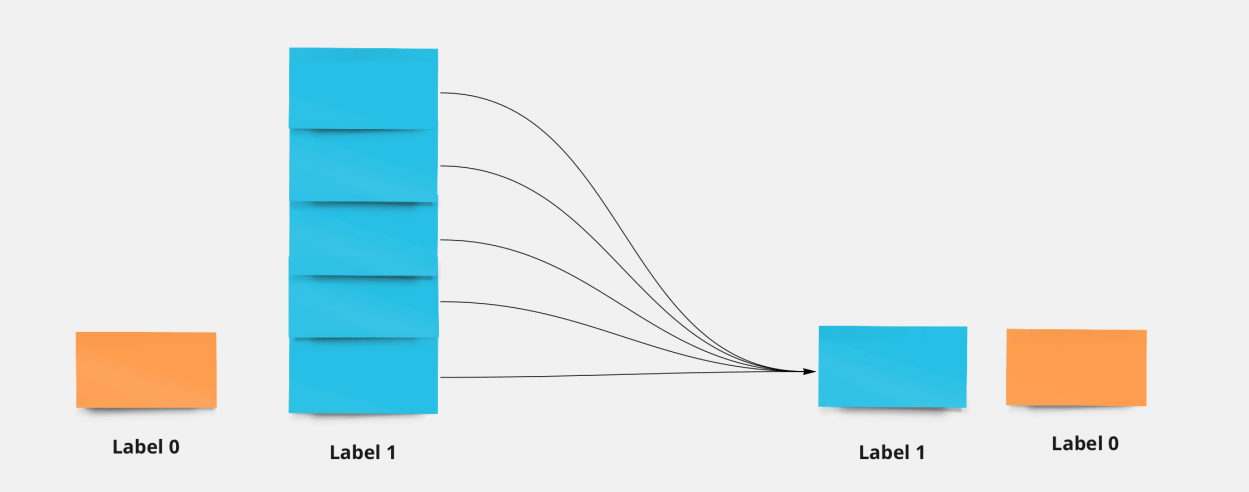


Figure 3 : Sous-échantillonnage

B. Sur-échantillonnage aléatoire

Contrairement au sous-échantillonnage, le sur-échantillonnage aléatoire consiste à sélectionner des exemples aléatoires de la classe minoritaire avec remplacement et à compléter les données d'apprentissage avec de multiples copies de cette instance

jusqu'à ce qu'une distribution plus équilibrée soit atteinte, il est donc possible qu'une seule instance soit sélectionnée plusieurs fois.

L'utilisation de cette technique peut conduire à un surajustement (*overfitting*) à la classe minoritaire, puisque le modèle est entraîné en utilisant les mêmes exemples. Un autre inconvénient du sur-échantillonnage est le long temps d'apprentissage, car cette technique conduit à augmenter la taille des données [25].

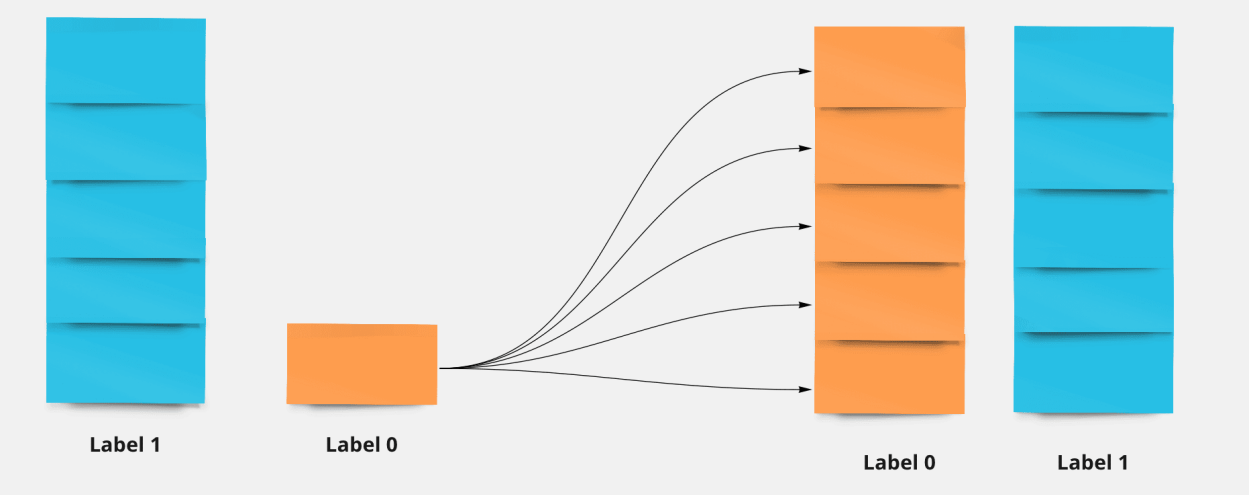


Figure 4 : Sur-échantillonnage

À noter que ces techniques d'échantillonnage s'appliquent seulement sur le sous-ensemble de l'entrainement, les données du test restent intouchables puisqu'elles représentent la réalité.

2.3.2 Algorithmes d'apprentissage

L'intelligence artificielle fournit une pléthore d'algorithmes de classification, pour la détection de la fraude à l'assurance maladie, les chercheurs ont testé et évalué de nombreuses approches [26].

Dans le cadre de notre projet, trois algorithmes de classification supervisée ont été choisis : Random Forest, XGBoost, et les réseaux de neurones, ce sont des algorithmes puissants qui ont prouvé leur domination en termes de performance par rapport aux modèles d'apprentissage classiques dans des différents domaines.

A. Random forest

Random Forest [27] (forêt aléatoire) est un algorithme **d'apprentissage ensembliste** pour la classification, la régression et d'autres tâches qui fonctionne en construisant une multitude **d'arbres de décision** [28] pendant son entrainement. Pour les tâches de classification, la sortie de la forêt aléatoire est la classe sélectionnée par la plupart des arbres.

L'apprentissage ensembliste est une approche de l'apprentissage automatique qui cherche à obtenir de meilleures performances prédictives en combinant les prédictions de plusieurs modèles ; Bien qu'il existe un nombre apparemment illimité d'ensembles

qu'on peut développer pour une problématique donnée, il existe trois méthodes qui dominent le domaine de l'apprentissage ensembliste :

- Le **Bagging** : implique l'ajustement de nombreux modèles sur différents échantillons du même ensemble de données et le calcul de la moyenne des prédictions.
- Le **Stacking** : implique l'ajustement de plusieurs modèles de types différents sur les mêmes données et l'utilisation d'un autre modèle pour apprendre comment combiner au mieux les prédictions.
- Le **Boosting** : consiste à ajouter séquentiellement des membres de l'ensemble qui corrigent les prédictions faites par les modèles précédents et à produire une moyenne pondérée des prédictions.

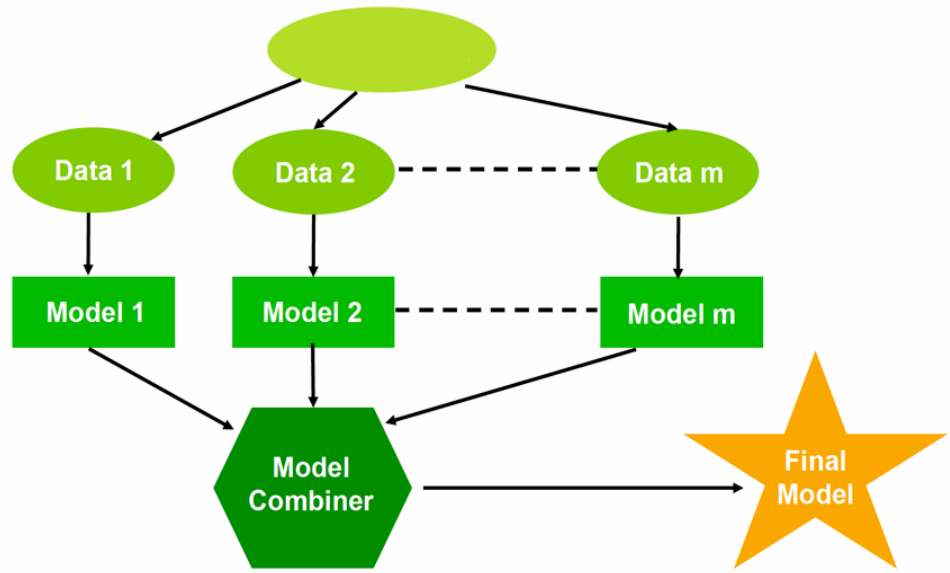


Figure 5 : Apprentissage ensembliste

Random forest appartient à la famille des algorithmes de bagging, plus précisément, il se base sur les arbres de décision. Les arbres de décision appartiennent à la famille des algorithmes d'apprentissage supervisé, l'algorithme de l'arbre de décision peut être utilisé pour résoudre des problèmes de régression et de classification.

Le principe général d'un arbre de décision est de créer un modèle qui peut être utilisé pour prédire la classe ou la valeur continue de la variable cible en apprenant des règles de décision simples déduites des données d'entrainement, les arbres sont construits à l'aide de deux types d'éléments : les nœuds et les branches.

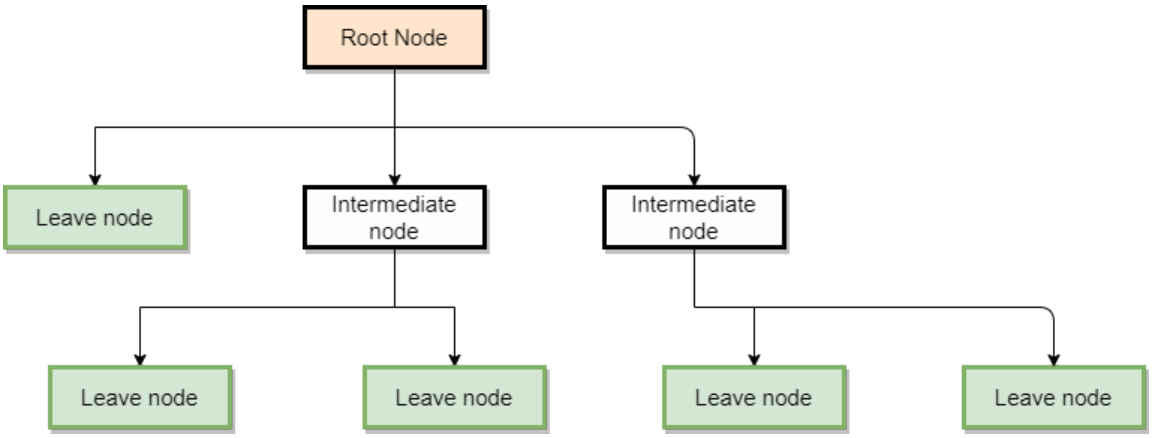


Figure 6 : Arbre de décision

La figure ci-dessus présente trois types de nœuds :

- **Le nœud racine** : C'est le point de départ de l'arbre, il évalue la variable qui divise le mieux les données.
- **Les nœuds intermédiaires** : Ce sont des nœuds où les variables sont évaluées.
- **Nœuds feuilles** : Ce sont les nœuds finaux de l'arbre, où les prédictions d'une catégorie ou d'une valeur numérique sont effectuées.

Les arbres de décision sont construits en divisant de manière récursive nos échantillons d'entraînement à l'aide des attributs des données qui fonctionnent le mieux pour notre problématique. Pour ce faire, l'algorithme évalue, pour chaque attribut, certaines métriques, comme l'indice de Gini ou l'entropie pour les arbres de décision catégoriels, ou l'erreur résiduelle ou l'erreur quadratique moyenne pour les arbres de régression.

Le processus est également différent si l'attribut que nous évaluons au niveau du nœud est discret ou continu. Pour les attributs discrets, toutes les valeurs possibles sont évaluées, ce qui donne lieu à **N** métriques calculées pour chacune des variables, **N** étant le nombre de valeurs possibles pour chaque valeur catégorique, pour les attributs continus, la moyenne de chacune des deux valeurs consécutives (ordre croissant) des données d'apprentissage est utilisée comme seuil possible. Le résultat de ce processus est, pour un certain nœud, une liste de variables, chacune avec différents seuils, et une métrique calculée (Gini ou MSE) pour chaque variable/seuil. Ensuite, nous choisissons la combinaison variable/seuil qui nous donne la valeur la plus élevée/la plus basse (selon le problème) pour la métrique choisie.

Pour les problèmes de classification, la métrique utilisée pour déterminer les attributs qui divisent le mieux les données est l'indice Gini, il s'agit une fonction utilisée pour évaluer les divisions dans l'ensemble de données. Il est calculé en soustrayant la somme des probabilités au carré de chaque classe de 1 :

Gini = 1-

L'indice de Gini fonctionne avec la variable cible catégorique « succès » ou « échec », il ne réalise que des splits binaires, une valeur plus élevée de l'indice de Gini

implique une plus grande inégalité, une plus grande hétérogénéité, l'attribut qui correspond à l'indice de Gini le plus faible est choisi.

Les arbres de décision ont toujours une condition d'arrêt de croissance, sinon ils se développeraient jusqu'à ce que chaque observation soit séparée en son propre nœud feuille. Ces conditions d'arrêt sont la profondeur maximale de l'arbre, le nombre minimal d'échantillons dans les nœuds feuilles ou la valeur minimale de la métrique choisie.

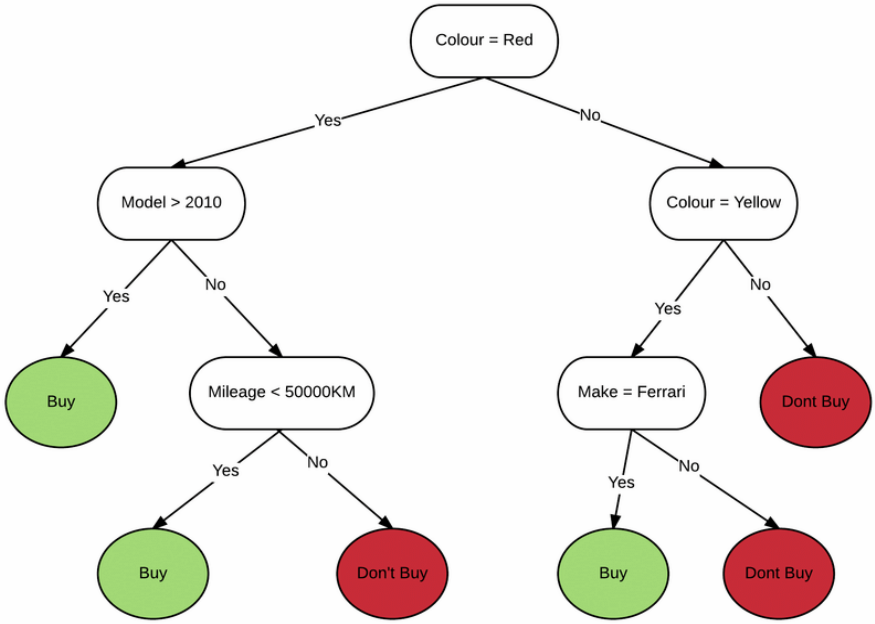


Figure 7 : Exemple d'un arbre de décision

L'un des inconvénients des arbres de décision, est le surajustement, afin de réduire ce problème, l'algorithme Random Forest consiste au bagging de plusieurs arbres de décision, c'est-à-dire, l'entrainement de plusieurs arbres de décision, chaque arbre est entrainé sur un sous-échantillon de données avec un certain nombre limité d'attributs, le résultat final est l'agrégation des résultats des arbres entrainés, les sous-échantillons sont choisis en utilisant la technique Bootstrap, qui consiste à sélectionner des exemples aléatoirement avec remplacement.

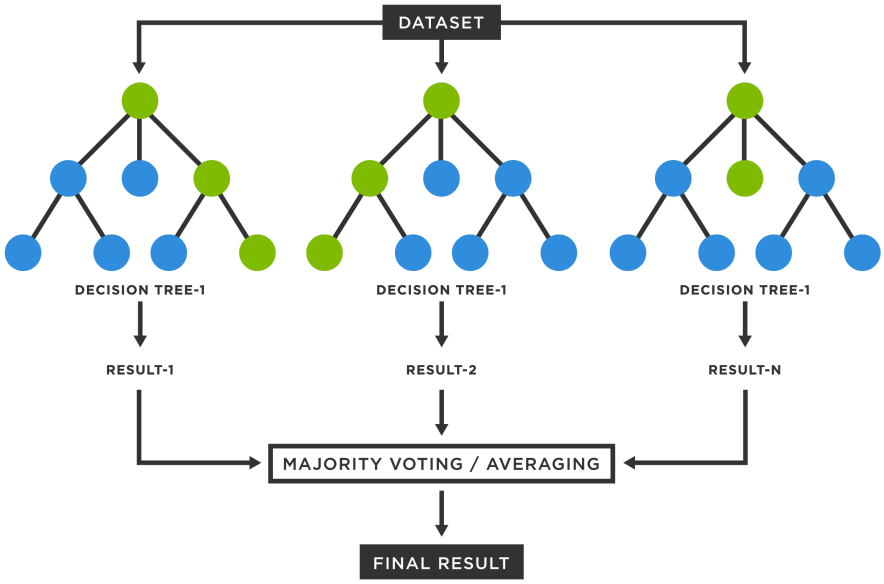


Figure 8 : Random Forest

B. XGBoost

e**X**treme **G**radient **Boost**ing (XGBoost) est une version évolutive et améliorée de l'algorithme de gradient boosting [29] conçue pour l'efficacité, la vitesse de calcul et la performance des modèles. Il s'agit d'une bibliothèque open-source qui fait partie de *Distributed (Deep) Machine Learning Community* [30], XGBoost est un mélange parfait de capacités logicielles et matérielles conçues pour améliorer les techniques de boosting existantes avec précision et en un minimum de temps.

Le Boosting signifie généralement l'amélioration des performances. Il s'agit d'une technique d'apprentissage séquentiel d'ensemble qui permet de convertir des « weak learners » en « strong learners » afin d'améliorer la performance du modèle.

L'algorithme de Boosting crée de nouveaux apprenants faibles (modèles), généralement des arbres de décision, et combine séquentiellement leurs prédictions pour améliorer les performances globales du modèle. Pour toute prédiction incorrecte, des poids plus importants sont attribués aux échantillons mal classés et des poids plus faibles aux échantillons correctement classés. Les modèles d'apprentissage faibles qui sont plus performants ont des poids plus élevés dans le modèle d'ensemble final. Le boosting ne modifie jamais le prédicteur précédent et corrige uniquement le prédicteur suivant en apprenant de ses erreurs. Il est recommandé de définir une condition d'arrêt telle que la performance du modèle (arrêt précoce) ou le nombre d'itérations (par exemple, la profondeur de l'arbre) afin d'éviter un surajustement des données d'entrainement.

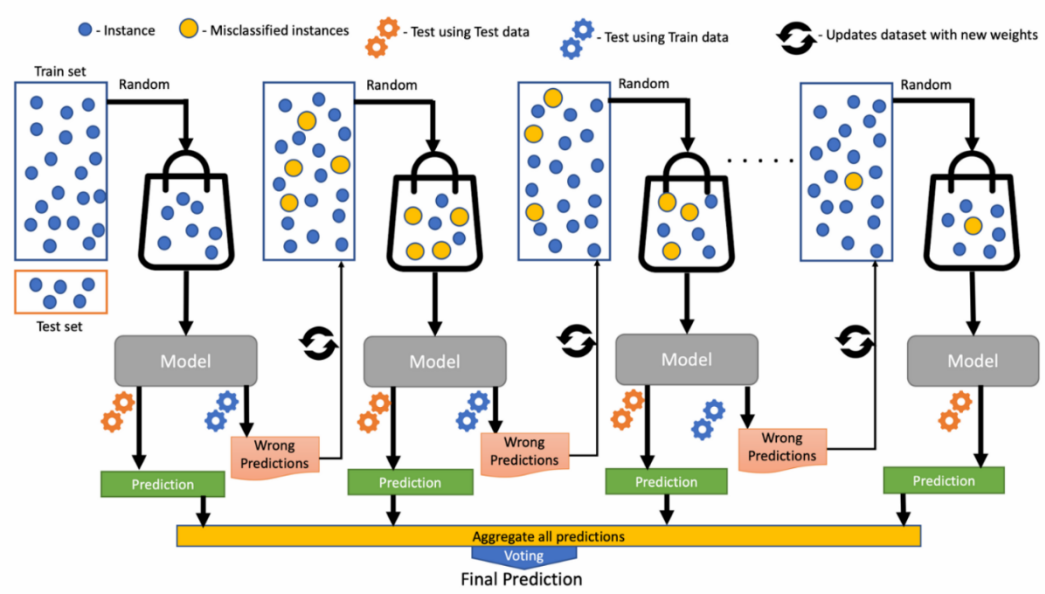


Figure 9 : Algorithme de Boosting

Gradient Boosting est un cas particulier d'algorithmes de boosting où les erreurs sont minimisées par un algorithme de **descente de gradient**, la principale différence entre le boosting et le gradient boosting est la manière dont les deux algorithmes mettent à jour le modèle (*weak learners*) à partir de prédictions erronées. Le Gradient Boosting ajuste les poids par l'utilisation du gradient (une direction dans **la fonction de coût**) en utilisant un algorithme appelé descente de gradient, qui optimise itérativement l'erreur du modèle en mettant à jour les paramètres.

La fonction de coût est une fonction qui mesure les performances d'un modèle d'apprentissage automatique pour des données d'entrée. La fonction de coût quantifie l'erreur entre les valeurs prévues et les valeurs attendues et la présente sous la forme d'un seul nombre réel. Selon le problème, la fonction de coût peut être formée de différentes manières. Le choix de la fonction de coût dépend du problème à résoudre.

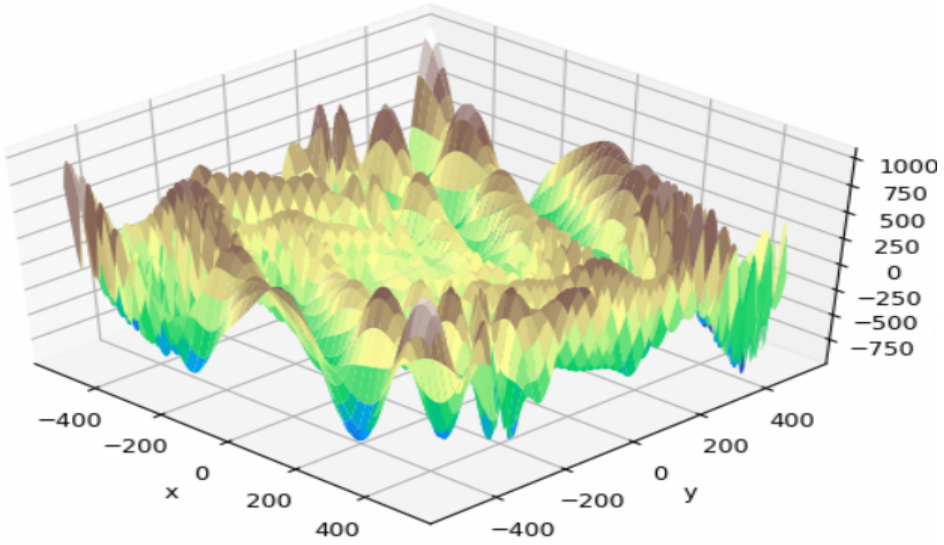


Figure 10 : Exemple d'une fonction de coût

L'objectif de la descente de gradient est de minimiser la fonction de coût, c'est-à-dire, trouver les valeurs des paramètres du modèle pour lesquels cette fonction renvoie la plus petite valeur possible. Les fonctions de coût sont généralement multidimensionnelles, et trouver leur minimum analytiquement n'est pas toujours évident.

Afin d'estimer un minimum à ces dernières on fait recours à l'algorithme descente de gradient (*gradient descent*). C'est une technique d'optimisation utilisée pour améliorer les performances en minimisant la fonction de coût. La figure suivante illustre cet algorithme (J(w) est la fonction de coût).

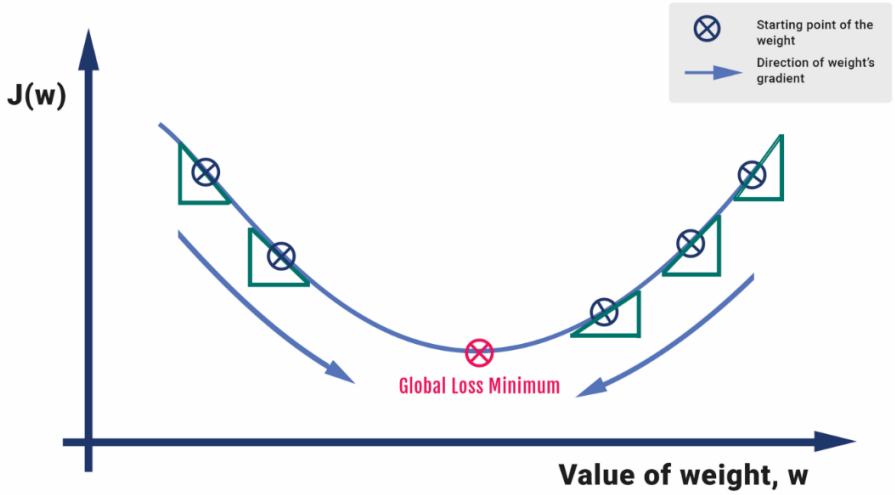


Figure 11 : Gradient descent

Gradient boosting utilise la modélisation additive dans laquelle un nouvel arbre de décision est ajouté à un modèle qui minimise la perte en utilisant la descente de gradient. Les arbres existants dans le modèle restent intacts et ralentissent ainsi le taux de surajustement. La sortie du nouvel arbre est combinée avec la sortie des arbres existants jusqu'à ce que la perte soit minimisée en dessous d'un seuil ou qu'une limite spécifiée d'arbres soit atteinte.

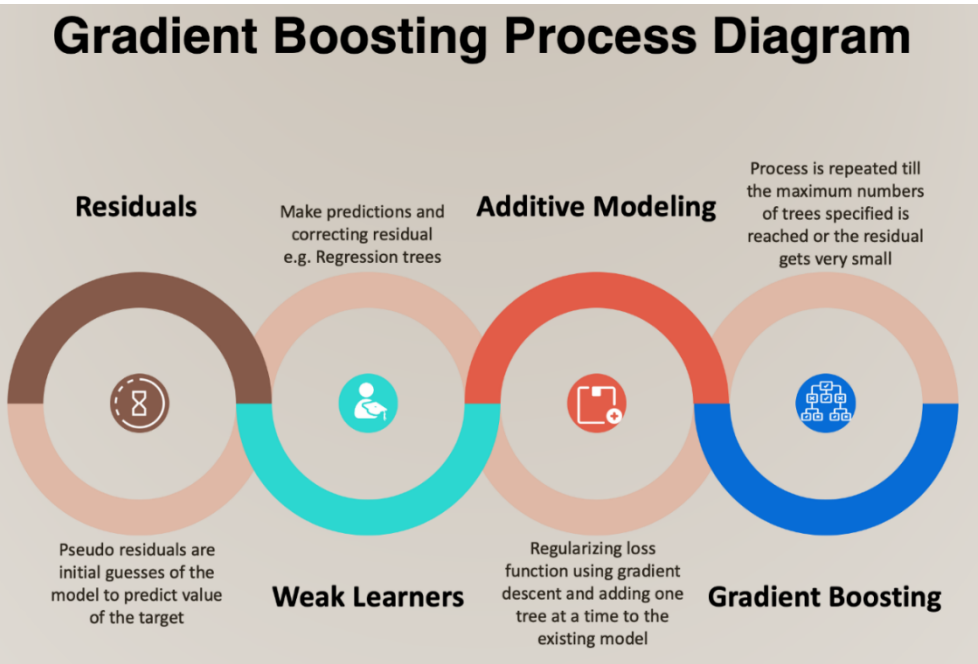


Figure 12 : XGBoost

L'implémentation de l'algorithme a été conçue de manière à optimiser le temps de calcul et les ressources matérielles. L'un des objectifs de la conception était de faire le meilleur usage possible des ressources disponibles pour former le modèle. Les principales caractéristiques de l'algorithme sont les suivantes :

- La parallélisation de la construction des arbres en utilisant tous les cœurs du CPU pendant l'entraînement.
- Calcul distribué pour l'apprentissage de très grands modèles à l'aide d'un cluster de machines.
- Calcul hors cœur pour les très grands ensembles de données qui ne tiennent pas en mémoire.
- Cache optimisation des structures de données et de l'algorithme afin d'utiliser au mieux le matériel.

C. Réseaux de neurones

Un réseau de neurones est un système informatique conçu pour simuler la façon dont le cerveau humain analyse et traite les informations. Il forme la base de l'apprentissage profond (*Deep Learning*), et résout des problèmes qui s'avéreraient impossibles ou difficiles par des méthodes statistiques classiques.

On retrouve plusieurs architectures de réseaux de neurones, le choix d'une architecture varie selon le type de problème, pour notre cas les réseaux multicouches sont les plus appropriés.

a. Perceptron monocouche

Le perceptron monocouche est le modèle le plus simple d'un neurone qui illustre le fonctionnement d'un réseau de neurones. Le perceptron est un algorithme d'apprentissage automatique développé en 1958 par *Frank Rosenblatt* [31] et mis en œuvre pour la première fois dans IBM 704. Le perceptron est un réseau qui prend un certain nombre d'entrées, effectue un certain traitement sur ces entrées et produit une sortie comme le montre la figure ci-dessous.

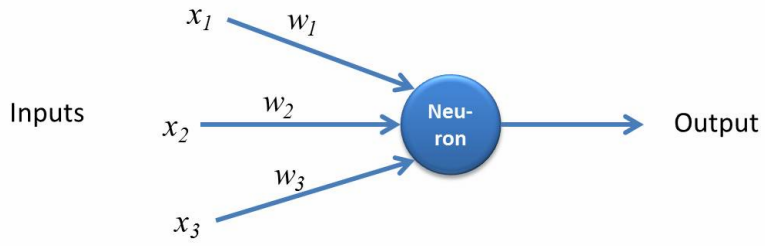


Figure 13 : Perceptron monocouche

L'importance de ces entrées est déterminée par les poids correspondants w1, w2 et w3 attribués à ces entrées. La sortie peut être un 0 ou un 1 selon la somme des entrées(*xj*) pondérées par leurs poids (*wj*) correspondants. La sortie est 0 si la somme est inférieure à un certain seuil ou 1 si la sortie est supérieure à un certain seuil. Ce seuil pourrait être un nombre réel et un paramètre du neurone. Puisque la sortie du perceptron peut être 0 ou 1, ce dernier est un exemple de classificateur binaire.

$$output = \begin{cases} 0 \ if \sum_j w_j x_j < threshold \\ 1 \ if \sum_j w_j x_j > threshold \end{cases}$$

Figure 14 : Sortie d'un perceptron

b. Perceptron multicouche

Un perceptron multicouche (MLP) [32] est un réseau neuronal artificiel. Il est composé de plus d'un perceptron. Ils sont composés d'une couche d'entrée pour recevoir le signal, une couche de sortie qui prend une décision ou une prédiction sur l'entrée, et entre ces deux, un nombre arbitraire de couches cachées qui sont le véritable moteur de calcul du MLP.

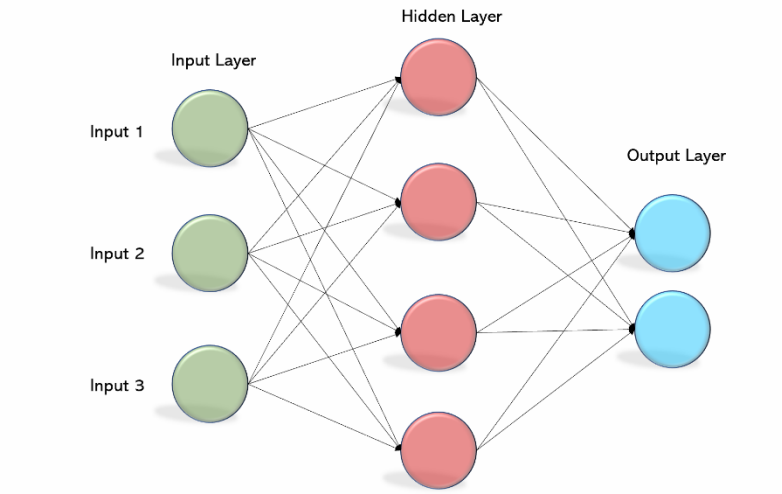


Figure 15 : Perceptron multicouche

Les perceptrons multicouches sont souvent appliqués aux problèmes d'apprentissage supervisé : ils s'entraînent sur un ensemble de paires entrées-sorties et apprennent à modéliser la corrélation (ou les dépendances) entre ces entrées et sorties. L'entrainement consiste à ajuster les paramètres, les poids et les biais, du modèle afin de minimiser les erreurs.

L'algorithme d'apprentissage calcule les paramètres (poids et biais) à l'aide de la propagation directe et de la rétropropagation.

1. **Propagation directe** : (Forward propagation) comme son nom l'indique, les données d'entrée sont acheminées vers l'avant via le réseau, chaque couche cachée prend les données d'entrée, les traite selon une fonction d'activation et passe à la couche successive.

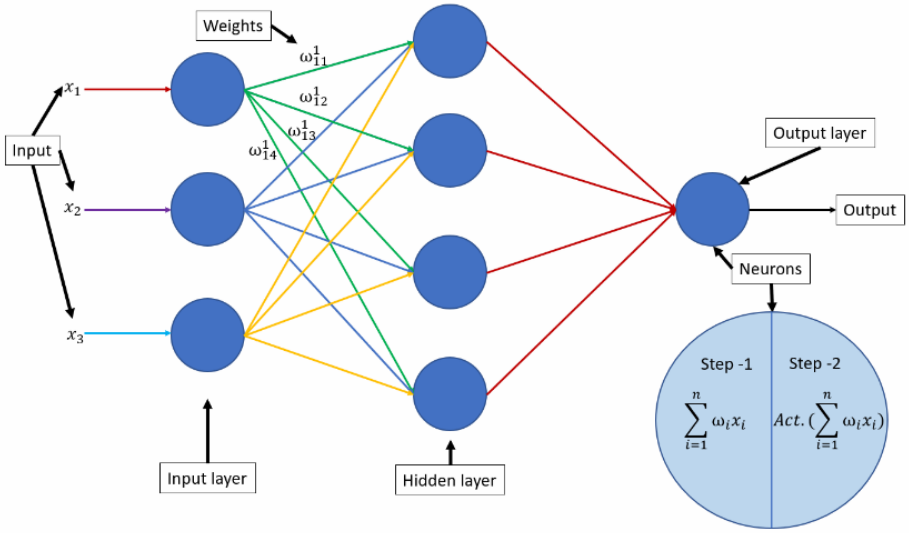


Figure 16 : Forward propagation

Au niveau de chaque neurone dans une couche cachée ou en sortie, le traitement se déroule en deux étapes :

- **Pré activation** : c'est une somme pondérée des entrées et leurs poids respectifs. Sur la base de cette somme cumulée et d'une fonction d'activation, le neurone décide s'il faut transmettre ces informations ou non.
  Y = + b

Avec aj les entrées, wj les poids et b le biais, le résultat de cette somme est passé ensuite à une fonction d'activation.

- **Activation** : le rôle principal d'une fonction d'activation c'est de décider si le prochain neurone doit être activé ou non. Le processus d'activation est inspiré de la biologie, c'est ainsi que le cerveau fonctionne. La somme pondérée (Y) des entrées calculées est transmise à la fonction d'activation, la valeur de Y peut aller de -∞ à +∞. Le neurone ne connaît vraiment pas les limites de Y, la fonction d'activation normalise cette valeur résultante entre 0 à 1 ou -1 à 1 etc. (selon la fonction choisie).
  Out = f(Y)
  Avec f la fonction d'activation, Y la somme pondérée et out la sortie du neurone.
  Il existe quatre fonctions d'activation couramment utilisées et populaires : sigmoïde, tangente hyperbolique, ReLU et Softmax.

2. **Rétropropagation :** c'est le cœur de la phase d'entrainement. Il s'agit du processus d'ajustement des poids d'un réseau de neurones en se basant sur le taux d'erreur obtenu à l'itération précédente. Un réglage correct des poids garantit des taux d'erreur plus faibles, ce qui rend le modèle plus performant.

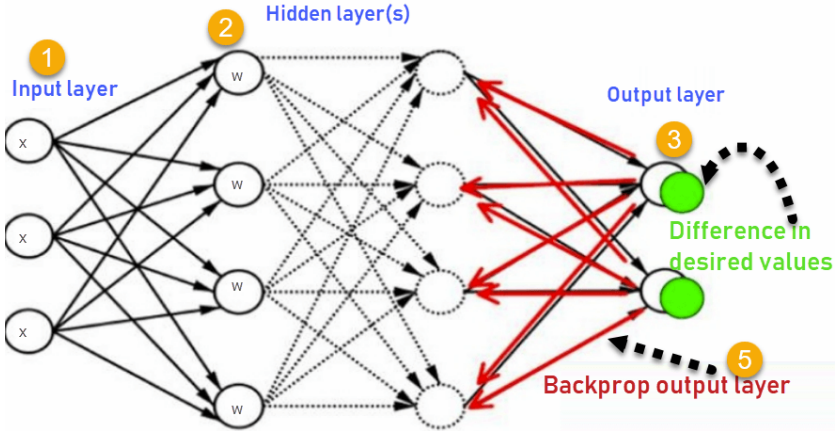


Figure 17 : Rétropropagation

L'objectif de la rétropropagation c'est de minimiser la fonction de coût du réseau en utilisant l'algorithme : descente de gradient.

Algorithme de descente de gradient :

1 Choisir des valeurs arbitraires des poids et de biais pour initialiser le modèle
2 Acheminer les données d'entrée vers l'avant via le réseau.
3 Calculer la fonction de coût, c’est-à-dire, le vecteur des erreurs du modèle.
4 Calculer le gradient comme la dérivée partielle de la fonction de coût par rapport à chaque paramètre (poids et biais) du réseau. Graphiquement, ce serait la pente de la tangente à la fonction de perte au point courant ; mathématiquement, c'est un vecteur qui nous donne la direction dans laquelle la fonction de perte augmente plus rapidement, donc nous devons nous déplacer dans la direction opposée si nous essayons de la minimiser.
5 Une fois le vecteur de gradient obtenu, nous mettrons à jour les paramètres du réseau par la soustraction de la valeur de paramètre actuelles de la valeur de gradient calculé par rapport à ce paramètre, multipliée par un taux d'apprentissage qui nous permet d'ajuster l'amplitude de nos pas.
6 On effectue la soustraction car, nous voulons nous déplacer dans la direction opposée au gradient, ce qui correspond à la direction du minimum de la fonction.
7 Répéter jusqu’à la convergence vers le minimum global.

2.4 Conclusion

Dans ce chapitre, nous avons présenté un état de l’art sur les différentes approches utilisées dans un contexte détection de fraude à l’assurance maladie, à travers les résultats obtenus par les chercheurs dans ce domaine, ainsi qu’une étude théorique des techniques utilisées.

3 Bases des données

3.1 Introduction

Dans ce chapitre, nous décrivons en détail les bases de données utilisées et discutons des étapes de prétraitement que nous suivons pour créer l'ensemble final de données annotées.

Nous avons choisi la base de données **Medicare Part B** fourni par CMS pour les années 2016 à 2019, à savoir *Medicare Provider Utilization and Payment Data : Physician and Other Supplier PUF* [11]. Cette base de données est utilisée dans de multiples études [12] [18] [17] [21].

Pour permettre l'apprentissage supervisé, un deuxième ensemble de données, ***List of Excluded Individuals and Entities*** *(LEIE)* [15] est utilisé pour étiqueter les fournisseurs au sein de l'ensemble de données Medicare Part B comme frauduleux ou non frauduleux.

3.2 CMS Medicare Part B

Medicare est un programme d'assurance maladie du gouvernement américain qui subventionne les services de santé. Ce régime couvre les personnes âgées de 65 ans ou plus, les personnes plus jeunes qui répondent à des critères d'éligibilité spécifiques et les personnes atteintes de certaines maladies. Medicare est divisé en différents plans qui couvrent une variété de situations en matière de soins de santé. Bien que cela permette au programme d'offrir aux consommateurs un plus grand choix en termes de coûts et de couverture, cela introduit également une certaine complexité pour ceux qui cherchent à s'inscrire. Medicare est divisé en différents plans qui couvrent une variété de situations en matière de soins de santé, bien que cela permet au programme d'offrir aux patients un plus grand choix en termes de coûts et de couverture, cela introduit également une certaine complexité pour ceux qui cherchent à s'inscrire [33].

La base de données Medicare Part B décrit les services et les procédures que les professionnels de la santé fournissent aux bénéficiaires de Medicare, les enregistrements de cet ensemble de données contiennent divers attributs relatifs au praticien, par exemple le National Provider Identifier (NPI), le nom et le prénom, le sexe, les références et l'adresse. Le NPI est un numéro d'identification unique à 10 chiffres pour les praticiens de soins de santé. En plus, la base de données contient des informations sur les demandes de remboursement qui décrivent l'activité d'un praticien dans le cadre de Medicare au cours d'une année donnée. Parmi les exemples de données relatives aux demandes de remboursement figurent la procédure effectuée, le montant moyen des frais soumis à Medicare, le montant moyen payé par Medicare et le lieu du service. Les données relatives aux demandes de remboursement comprennent également le type de praticien : une valeur catégorique décrivant la spécialité du praticien.

Pour chaque publication annuelle, la CMS regroupe les données selon :

- NPI du praticien ;

- NPI + codes HCPCS (*Healthcare Common Procedures Coding* System) : codes utilisés pour facturer les différents services ;
- Géographie + codes HCPCS.

Pour notre cas, nous avons choisi les données agrégées au niveau NPI, un échantillon de la base de données 2019 est présenté dans la figure suivante :

Rndrng_NPI	Rndrng_Prvdr_Gndr	Rndrng_Prvdr_Type	Tot_Benes	Tot_Srvcs	Tot_Sbmtd_Chrg	Tot_Mdcr_Pymt_A…
1003000126	M	Internal Medicine	610	1,392	$519,136.00	$124,877.67
1003000134	M	Pathology	3,614	7,835	$1,213,264.00	$228,078.56
1003000142	M	Anesthesiology	264	2,530	$215,156.00	$83,582.18
1003000423	F	Obstetrics & Gynecology	74	897	$23,150.00	$9,007.31
1003000480	M	General Surgery	104	159	$210,964.25	$31,113.49
1003000522	M	Family Practice	374	1,319	$349,343.44	$86,736.63
1003000530	F	Internal Medicine	347	1,485	$234,676.00	$112,451.04
1003000597	M	Urology	796	3,948	$951,912.50	$242,309.70
1003000639	M	Cardiac Surgery	84	181	$793,301.50	$84,335.70
1003000704	M	Anesthesiology	107	121	$92,785.00	$18,092.78

Figure 18 : Echantillon données Medicare

Avec 73 attributs décrivant les demandes soumises par les praticiens, et plus d'un million d'enregistrements par an, cette base de données publique est un excellent candidat pour l'analyse de données et l'apprentissage automatique. Malheureusement, il n'est pas prêt à être utilisé pour la détection des fraudes. Dans la section suivante, nous présenterons une deuxième base de données utilisée pour associer les étiquettes de fraude au praticien répertorié dans l'ensemble de données Medicare Part B.

3.3 LEIE data

Les étiquettes de fraude des praticiens de Medicare sont identifiées en utilisant les données publiques du LEIE. La base de données LEIE est gérée par l'OIG (*office of inspector general*) et mise à jour mensuellement.

L'OIG [34] fait partie du département américain de la santé et des services sociaux (HHS), il compte plus de 1 600 enquêteurs et auditeurs répartis dans des centres dans tout le pays. Institué en 1976, son unique objectif est de protéger les programmes du HHS et les bénéficiaires de ces programmes. L'OIG concentre son énergie sur la découverte et la prévention des fraudes et des abus dans des centaines de programmes du HHS, par exemple Medicare.

L'OIG a le pouvoir d'exclure les praticiens des programmes de soins de santé financés par le gouvernement fédéral, comme Medicare, pour diverses raisons, les personnes exclues ne peuvent pas recevoir de paiement de la part des programmes de santé fédéraux pour quelque service que ce soit, et doivent demander leur réintégration une fois que la période d'exclusion a été satisfaite. La base de données actuelle du LEIE contient 18 attributs qui décrivent le praticien et la raison de son exclusion. La figure ci-dessus présente un échantillon de la base de données LEIE, certains attributs supplémentaires non répertoriés incluent le prénom et le nom, la date de naissance, et l'adresse du praticien.

	SPECIALTY	NPI	STATE	EXCLTYPE	EXCLDATE	REINDATE	WAIVERDATE
1	PHARMACY	1972902351	NY	1128b8	20220320	0	0
4	PHARMACY	1922348218	NY	1128a1	20180419	0	0
24	DME - GENERAL	1942476080	NY	1128b8	20170518	0	0
28	HOME HEALTH AGENCY	1275600959	OH	1128a1	20130320	0	0
31	PHARMACY	1891731758	NY	1128b8	20170518	0	0
60	MENTAL/BEHAVIORAL HE	1851631543	WI	1128b7	20190326	0	0
61	COMM MNTL HLTH CNTR	1902198435	NV	1128a1	20160120	0	0
62	CONSULTING FIRM	1073916631	IN	1128b7	20210816	0	0

Figure 19 : Echantillon données LEIE

L'attribut de type d'exclusion de LEIE est une valeur catégorique qui décrit la raison pour laquelle un praticien a été exclu, Conformément aux travaux de *Bauder et Khoshgoftaar* [12], un sous-ensemble de règles d'exclusion qui sont les plus indicatives de fraude est sélectionné pour étiqueter les praticiens de Medicare. La figure suivante contient la liste des règles d'exclusion utilisées pour l'annotation des données ainsi que leurs périodes d'exclusion minimum.

Social Security Act	Description	Minimum exclusion period
1128(a)(1)	Conviction of program-related crimes	5 years
1128(a)(2)	Conviction relating to patient abuse or neglect	5 years
1128(a)(3)	Felony conviction relating to health care fraud	5 years
1128(b)(4)	License revocation, suspension, or surrender	State dependent
1128(b)(7)	Fraud, kickbacks, and other prohibited activities	None
1128(c)(3)(G)(i)	Conviction of second mandatory exclusion offenses	10 years
1128(c)(3)(g)(ii)	Conviction of third mandatory exclusion offenses	Permanent exclusion

Figure 20 : Règles LEIE relatives à la fraude

Les numéros NPI des personnes exclues qui ont été condamnés en vertu de l'une de ces règles sont utilisés pour identifier les praticiens frauduleux dans l'ensemble de données Medicare Part B, pour ces praticiens dans l'ensemble de données Medicare Part B, dont le numéro NPI correspond à celui de l'ensemble de données LEIE, les demandes de remboursement qui sont antérieures à la date d'exclusion du praticien sont étiquetées comme frauduleuses. Ainsi, nous supposons que la réclamation d'un praticien avant la date de son exclusion de Medicare reflète une activité frauduleuse, puisqu'il a été condamné peu après.

L'ensemble de données LEIE est incomplet et contient des valeurs manquantes, par exemple des numéros NPI manquants indiqués par des valeurs 0. En outre, il y a probablement beaucoup plus de praticiens de Medicare coupables de fraude qui n'ont pas été condamnés et qui ne sont donc pas inclus dans la base de données le LEIE, puisque c'est le seul mécanisme par lequel nous pouvons étiqueter les praticiens de Medicare comme frauduleux, il y aura un certain nombre de prestataires frauduleux qui seront étiquetés à tort comme non frauduleux.

3.4 Annotation des donnés

Les étiquettes de praticiens frauduleux sont générées en faisant correspondre les numéros NPI des individus exclus de la base de données LEIE à la base de données Medicare Part B, l'une des limites de cette approche est que l'ensemble des données LEIE liste les numéros NPI d'une petite fraction des individus exclus, par exemple 25% en février 2019.

Comme les données Medicare Part B et LEIE ont des dates de publication différentes, *Herland et al.* [35] ont décidé d'arrondir les dates de fin d'exclusion à l'année la plus proche, dans certaines circonstances, l'OIG a le droit de renoncer à une exclusion et de permettre aux prestataires de continuer à exercer, ce qui est indiqué par l'attribut : date de renonciation (*waiver date*). En prenant la date de fin d'exclusion comme le minimum de la date d'exclusion et de la date de renonciation, les praticiens sont marqués comme frauduleux pour une année donnée s'ils sont sur la liste d'exclusion pendant la majorité de cette année, par exemple, si un prestataire a une

date de fin d'exclusion de juillet 2018, sa date de fin d'exclusion sera arrondie à 2019 car il a été répertorié comme frauduleux pendant plus de la moitié de 2018. En revanche, si la date de fin d'exclusion d'un prestataire est de mars 2018, sa date de fin d'exclusion sera arrondie à 2018.

Si un praticien a une date de fin d'exclusion pour une année donnée, toutes les demandes de remboursement antérieures à cette année sont considérées comme frauduleuses pour ce praticien, à titre d'exemple : un praticien dont la date d'exclusion est le 2019-02-20 aura une nouvelle date de fin d'exclusion fixée à 2019, ce praticien est mis en correspondance avec les données de la partie B à travers le NPI et toutes les demandes soumises avant l'année 2019 sont étiquetées comme frauduleuses, c'est-à-dire les demandes de 2016 jusqu'à 2019.

3.5 Base de données finale

La base de données finale est formée par la jointure de la base de données Medicare Part B et de la base de données LEIE, dans un premier nous avons commencé par la concaténation des tables de la base des données Medicare des années 2016 jusqu'à 2019, après nous avons suivi les mêmes étapes indiquées dans la section précédente pour l'annotation des données : l'ajout de l'étiquette qui indique l'état d'un praticien.

Comme nous nous intéressons principalement à la détection de la fraude en fonction des informations relatives aux réclamations, de nombreux attributs sont supprimés des données Medicare, par exemple le nom et l'adresse du praticien, Parmi les 73 attributs initiaux des données Medicare, nous avons conservé 13 attributs contenant des informations essentielles sur les réclamations et les praticiens, la liste d'attributs qui en résulte et leurs types de données correspondants sont présentés dans la tableau ci-dessus :

Attribut	Description	Type
Rndrng_NPI	Identifiant d'un praticien.	Numérique
Rndrng_Prvdr_State_Abrvtn	Etat dans lequel le praticien est situé.	Catégorielle
Rndrng_Prvdr_Gndr	Sexe d'un praticien.	Catégorielle
Rndrng_Prvdr_Type	Spécialité d'un praticien.	Catégorielle
Tot_Srvcs	Nombre total des services effectué par un praticien.	Numérique
Tot_Benes	Nombre total de bénéficiaires de Medicare	Numérique

	recevant des services du praticien.	
Tot_Sbmtd_Chrg	Total des frais que le prestataire a soumis pour tous les services.	Numérique
Tot_Mdcr_Pymt_Amt	Montant total payé par Medicare.	Numérique
Tot_HCPCS_Cds	Nombre total de codes HCPCS uniques.	Numérique
Bene_Male_Cnt	Nombre de patients de sexe masculin.	Numérique
Bene_Avg_Age	Age moyen des patients.	Numérique
Bene_Avg_Risk_Scre	Score moyen de risque de *Hierarchical Condition Category* (HCC) [36] des patients.	Numérique
Year	Année correspondante.	Catégorielle
Fraud	Etiquette.	Catégorielle

Tableau 2 : Liste des attributs

Après avoir terminé les différentes étapes de la préparation des données, La base de données finale contient des informations sur 4 419 977 praticiens, dont 1276 sont frauduleux, ce qui représente un peu prés de 0.03 % de l'effectif total.

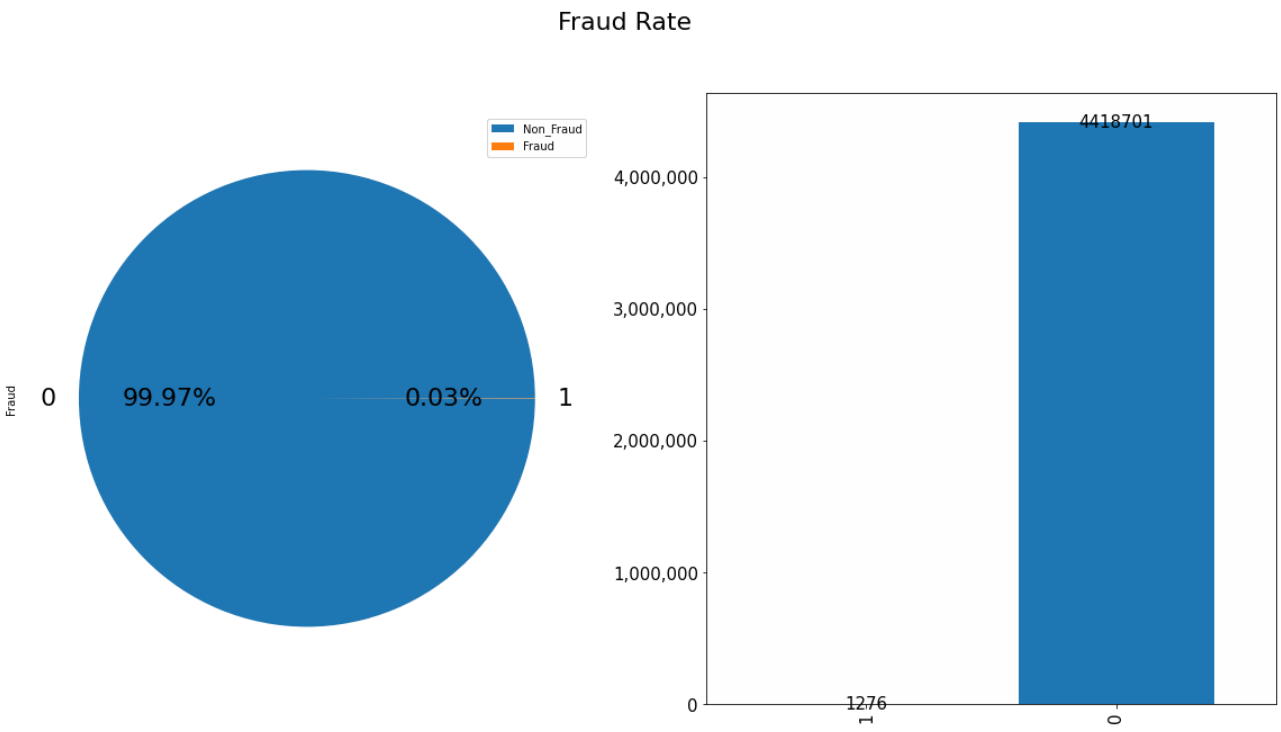


Figure 21 : Taux de fraude

3.6 Conclusion

Dans ce chapitre, Nous avons présenté les étapes de préparation des données, tout en détaillant les bases de données utilisées, nous avons également présenté les différentes caractéristiques de la base de données finale. Dans les prochains chapitres, Nous présenterons la méthodologie suivie pour l'élaboration de notre projet.

4 Méthodologie

4.1 Introduction

Le but de ce chapitre est de présenter la méthodologie suivie pour l'élaboration de notre projet, nous expliquons dans un premier lieu le cycle OSEMN, ensuite nous présentons les principaux outils de réalisation, et finalement nous présentons les résultats de l'exploration des données.

4.2 Cycle OSEMN

Le cycle OSEMN a été décrit à l'origine par *Hilary Mason* et *Chris Wiggins* [37], il s'agit d'une méthode utile pour la décomposition des projets d'analyse de données et intelligence artificielle. L'OSEMN comporte cinq étapes principales :

- **Obtain** : la toute première étape d'un projet de science des données est simple, il s'agit de la recherche et de l'acquisition des données dont nous avons besoin à partir des sources de données disponibles.
- **Scrub** : après avoir obtenu les données, la prochaine étape immédiate est le nettoyage des données, cela comprend des opérations telles que la suppression des données non pertinentes et dupliquées, la correction des erreurs structurelles des attributs et le traitement des valeurs manquantes.
- **Explore** : la troisième étape du cycle OSEMN et l'exploration, c'est le processus consistant à effectuer des recherches initiales sur des données afin de découvrir des motifs, de repérer des anomalies, de tester des hypothèses et de vérifier la distribution des données à l'aide de méthodes statistiques et de représentations graphiques.
- **Model** : c'est le processus de développement et d'évolution des modèles prédictifs, il commence généralement par la division des données en sous-ensembles d'entraînement et de test et le prétraitement des données, l'étape suivante consiste à tester différents algorithmes en fonction du problème donné, et à améliorer les performances du modèle en optimisant les paramètres du modèle.
- **Interpret :** la dernière étape de notre pipeline consiste à la présentation des résultats à un non-spécialiste, l'accent serait mis sur les réponses aux besoins fonctionnels définis dans le début du projet, ainsi que les informations exploitables obtenues au cours du projet.

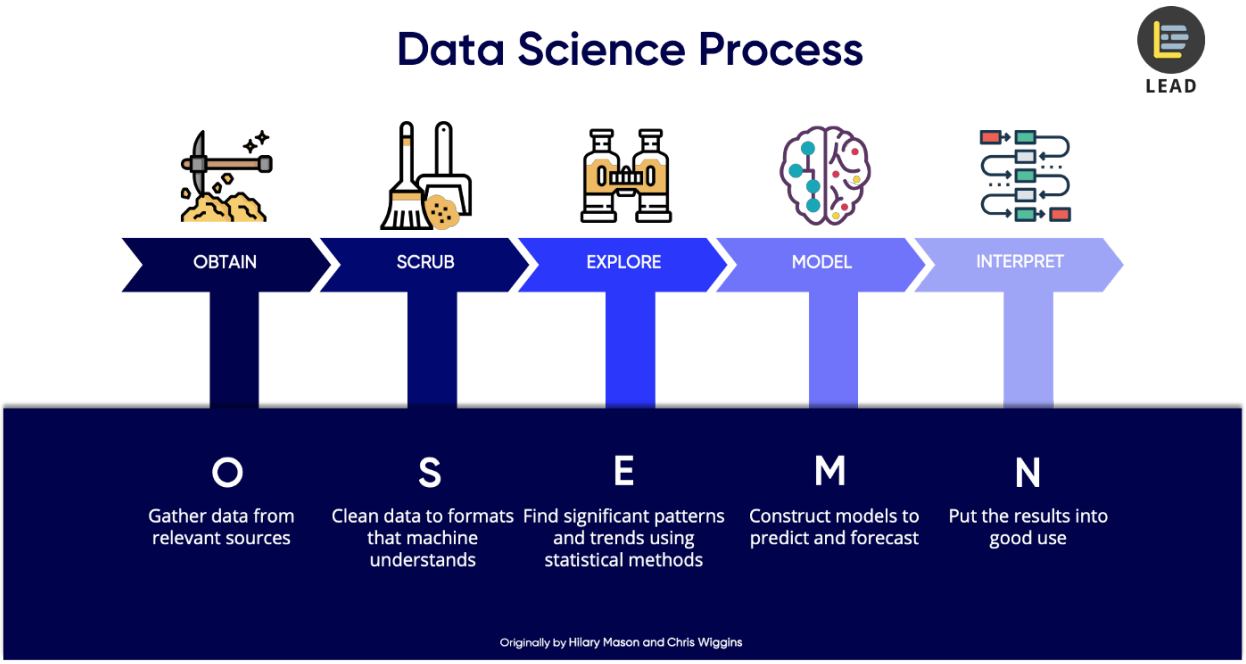


Figure 22 : OSEMN Framework

Pour l'élaboration de notre projet, nous nous sommes basés sur le cycle OSEMN pour la structuration des différentes tâches.

4.3 Outils de développement

Python est le langage de programmation le plus utilisé dans le domaine du Machine Learning, du Big Data et de la Data Science. C'est un langage de programmation interprété, orienté objet, avec une sémantique dynamique. Ses structures de données intégrées, combinées à un typage dynamique, le rendent très attrayant pour le développement rapide d'applications.

Pandas est une bibliothèque Python pour l'analyse et visualisation de données, développée en 2008 pour répondre au besoin d'un outil d'analyse quantitative puissant et flexible, pandas est devenue l'une des bibliothèques Python les plus populaires. Pandas est construite sur la base de deux bibliothèques Python essentielles : *matplotlib* pour la visualisation des données et *NumPy* pour les opérations mathématiques.

Scikit-learn est la bibliothèque la plus utile et la plus robuste pour automatique en Python. Elle d'outils efficaces pour automatique et la modélisation la classification, la régression, le

l'apprentissage
fournit une sélection
l'apprentissage
statistique, notamment

regroupement et la réduction de la dimensionnalité, via une interface cohérente en Python. Cette bibliothèque, qui est en grande partie écrite en Python, s'appuie sur d'autres bibliothèques célèbres telles que NumPy, SciPy et matplotlib.



La bibliothèque **Imblearn** est spécialement conçue pour traiter les ensembles de données déséquilibrés. Elle fournit diverses méthodes comme le sous-échantillonnage et le sur-échantillonnage pour traiter le déséquilibre de l'ensemble de données.

4.4 Nettoyage des données

Après avoir discuté en détail la partie acquisition et préparation de données dans le chapitre précédent, l'étape suivante dans le cycle OSEMN est le nettoyage des données, l'objectif est d'avoir une base de données propre, fiable, cohérente et complète, des données propres sont des données de haute qualité, des données auxquelles nous pouvons faire confiance et sur lesquelles nous pouvons prendre les bonnes décisions, de plus la qualité d'un modèle d'apprentissage dépend fortement de la qualité des données sur lesquels il s'est entrainé.

Les principales opérations effectuées lors du nettoyage des données sont :

- **Vérification des types des variables** : tous les types de données sont valides ;
- **Vérification et traitement des valeurs nulles :**

Variable	Pourcentage des valeurs nulles
Rndrng_Prvdr_Gndr	5.547 %
Bene_Male_Cnt	11.064 %

Tableau 3 : Pourcentage des valeurs nulles

Des valeurs manquantes ont été trouvées dans deux attributs : le sexe du praticien (5.5% des valeurs nulles) et le nombre total de patients masculins (11.06% des valeurs nulles). Pour la variable catégorielle (sexe), les lignes correspondant aux valeurs nulles ont été supprimées de l'ensemble de données, quant à la valeur numérique (nombre total de patients masculins), les valeurs nulles ont été remplacées par la médiane ;

- **Vérification des enregistrements dupliqués** : aucun enregistrement dupliqué trouvé ;
- **Vérification des valeurs négatives** : aucune valeur négative trouvée pour les variables numériques.

Les données sont maintenant nettoyées et prêtes à être exploitées, l'étape suivante est l'exploration et la visualisation des données.

4.5 Exploration des données

L'analyse exploratoire des données (EDA) est le processus de visualisation et d'analyse des données pour en extraire des informations pertinentes. Les principaux éléments de l'analyse exploratoire des données sont l'analyse statistique, la visualisation des données et la relation entre les variables, L'analyse exploratoire des données nous permet de :

- Donner une meilleure compréhension de l'ensemble des données.
- Détecter les valeurs aberrantes ou les événements anormaux.
- Mieux comprendre des variables de l'ensemble de données et de la relation entre elles.

4.5.1 Taux de fraude

Comme indiqué dans le chapitre précédent, le taux de fraude présent dans la base des données finale est 0.03%, c'est-à-dire que pour 10 000 praticiens, seulement trois sont frauduleux, ce petit pourcentage ne représente pas la situation réelle au Maroc qui est d'environ 10% selon [7], par conséquent, nous avons besoin d'un moyen pour amener le taux de fraude dans notre ensemble de données pour être aussi proche que possible de la situation au Maroc, pour ce faire, un échantillon du sous-ensemble de praticien non frauduleux est prélevé de sorte que le taux de fraude serait égal à 10%.

L'échantillon prélevé doit être non biaisé, c'est-à-dire représentatif de la population (le sous-ensemble des praticiens non frauduleux), la signification statistique par rapport à la population ne doit pas être perdue. Il existe de nombreuses façons de prélever un échantillon à partir d'une population, la méthode la plus simple consiste à prendre un sous-échantillon aléatoire avec une distribution uniforme et à vérifier s'il est statistiquement significatif ou non. S'il est raisonnablement significatif, l'échantillon est gardé. S'il ne l'est pas, un autre échantillon est prélevé pour être vérifié, cette procédure est répétée jusqu'à ce qu'un échantillon représentatif soit sélectionné.

Dans le cas d'un ensemble de données composé de N variables, il est possible de le regrouper dans un histogramme à N variables et d'échantillonner à partir de ce dernier, cette méthode, bien qu'elle soit théoriquement correcte, peut être très difficile à mettre en œuvre dans la réalité, surtout si l'ensemble de données contient un mélange de variables numériques et catégorielles. Une autre approche consiste à considérer chaque variable indépendamment des autres. Si chacun des histogrammes univariés des colonnes de l'échantillon est assez similaire à l'histogramme correspondant des colonnes de la population, nous pouvons considérer que l'échantillon n'est pas biaisé, la comparaison entre l'échantillon et la population se fait alors de la manière suivante :

1. Prendre une variable de l'échantillon ;
2. Comparez sa distribution de probabilité avec la distribution de probabilité de la même variable de la population ;
3. Répétez l'opération avec toutes les variables

Cette comparaison est effectuée avec des test d’hypothèse statistiques, les variables catégorielles sont comparées à l'aide du test du Chi-deux [38], tandis que les variables numériques sont comparées à l'aide du test de Kolmogorov-Smirnov [39]. Les

deux tests statistiques reposent sur l'hypothèse nulle que l'échantillon a la même distribution que la population. Étant donné qu'un échantillon est composé de nombreuses colonnes et que celles-ci doivent toutes être significatives, il est possible de rejeter l'hypothèse nulle si la valeur p(p-value) d'au moins un des tests est inférieure au niveau de confiance habituel de 5 %, en d'autres termes, nous voulons que chaque colonne passe le test de signification afin d'accepter l'échantillon comme valide.

Après avoir sélectionné l'échantillon représentatif, nous avons maintenant une base de données où le taux de fraude est de 10%, ce qui est proche de la situation ici au Maroc, la nouvelle base de données comporte 12470 enregistrements, dont 1247 sont frauduleux.

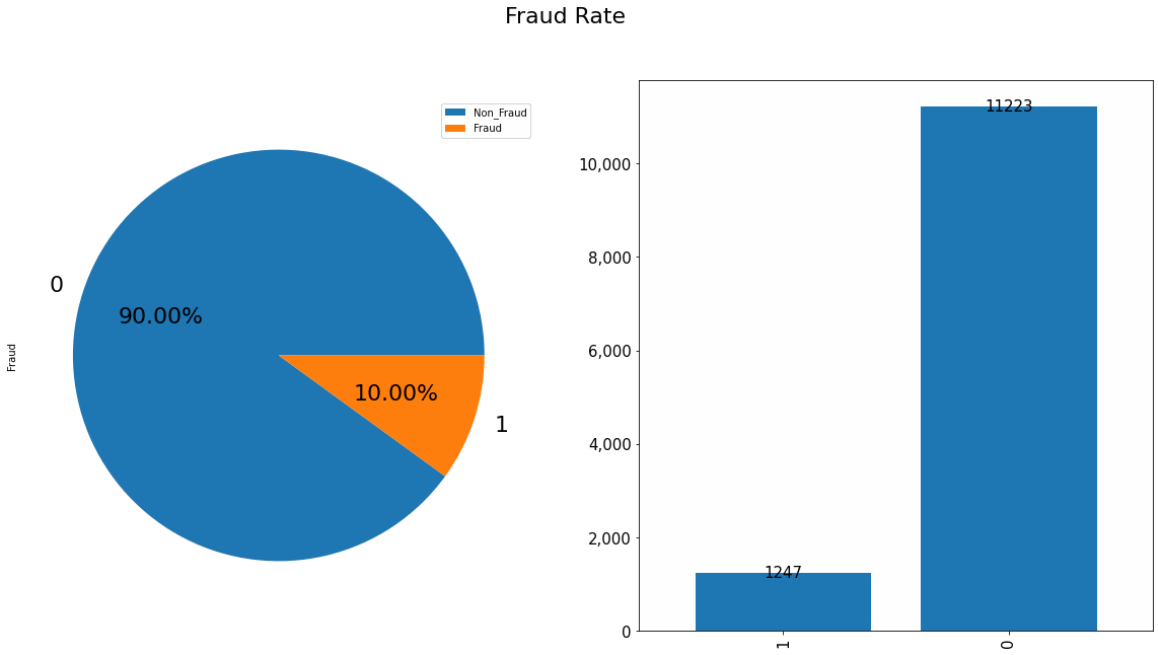


Figure 23 : Taux de fraude après échantillonnage

4.5.2 Analyse univarié

L'analyse univariée explore chaque variable d'un ensemble de données, séparément, l'objectif est de décrire les variables de manière indépendante.

A. Variables numériques

Notre base de données finale comporte 8 variables numériques :

- **Tot_Srvcs** : nombre total des services.
- **Tot_Benes** : nombre total des patients.
- **Tot_Sbmtd_Chrg** : total des frais soumis.
- **Tot_Mdcr_Pymt_Amt** : montant total payé par Medicare.
- **Tot_HCPCS_Cds** : total des codes HCPCS uniques.
- **Bene_Male_Cnt** : total des patients de sexe masculin.
- **Bene_Avg_Age** : âge moyen des patients.

- **Bene_Avg_Risk_Scre** : Score moyen de risque des patients.

a. Boite à moustaches

La boîte à moustaches (*Boxplot*) est un outil qui permet de résumer un ensemble de données en cinq nombres, le minimum, le premier quartile, la médiane, le troisième quartile et le maximum, ce type de graphique est utilisé pour détecter facilement les valeurs aberrantes (*outliers*), en utilisant la méthode IQR (Écart interquartile).

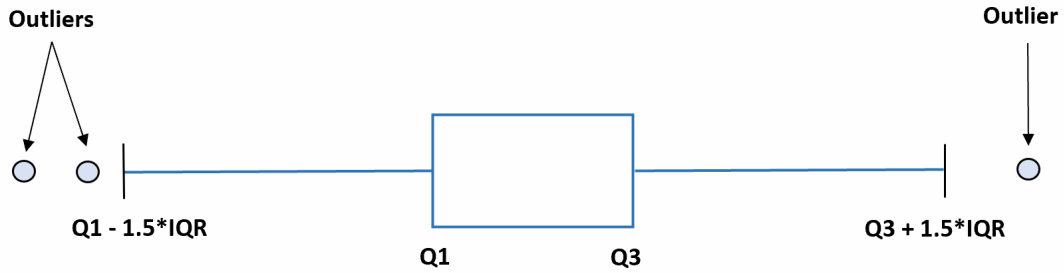


Figure 24 : Boite à moustaches

Les boites à moustaches pour les variables numériques de notre ensemble de données :

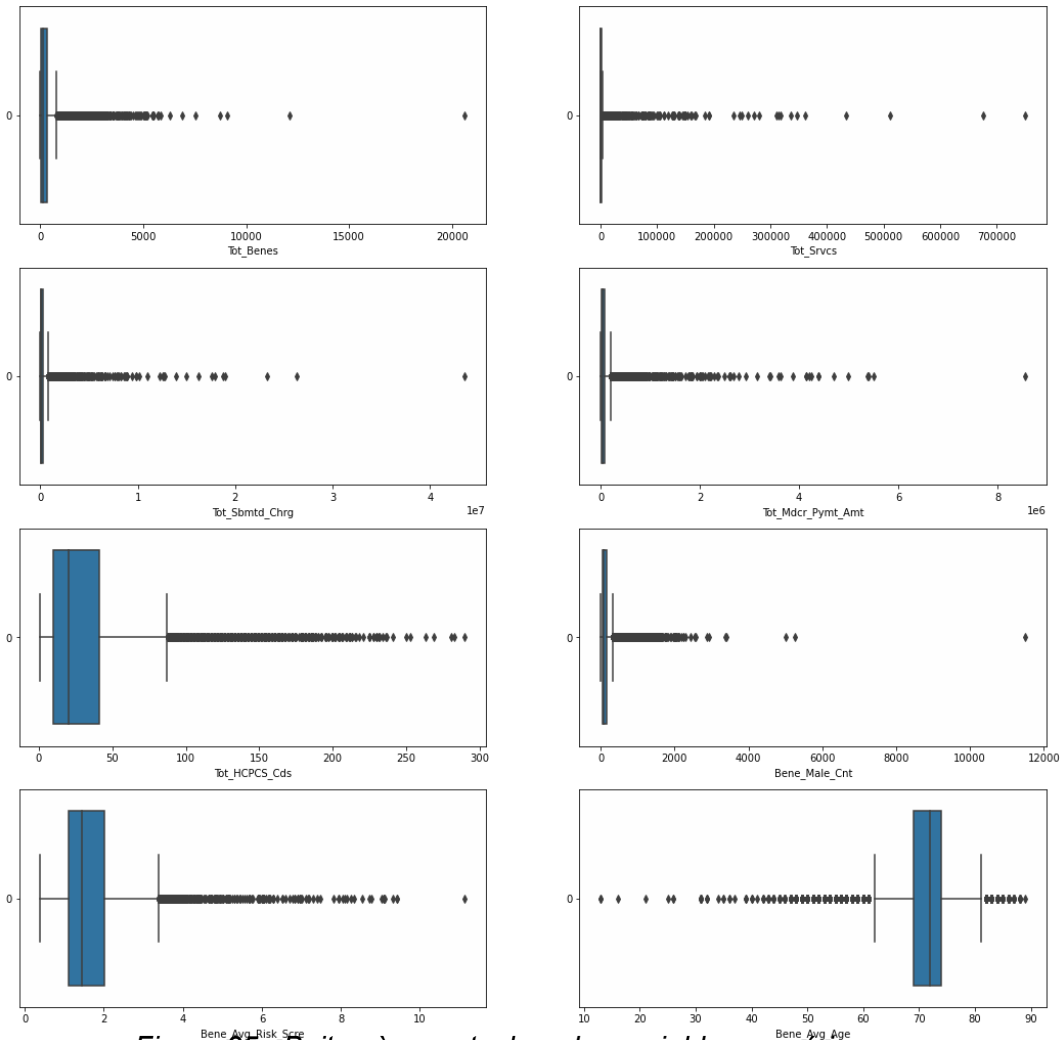


Figure 25 : Boites à moustaches des variables numériques

D'après la figure ci-dessus, il est clair qu'il y a des valeurs aberrantes présentes dans la base de données, la visualisation de la distribution des variables serait difficile avec la présence de ces valeurs.

Variables	Outliers	Pourcentage
Tot_Srvcs	1474	11.820%
Tot_Sbmtd_Chrg	1207	9.679%
Tot_Mdcr_Pymt_Amt	1201	9.631%
Bene_Avg_Age	1131	9.070%
Bene_Male_Cnt	1083	8.685%

Tot_Benes	953	7.642%
Tot_HCPCS_Cds	655	5.253%
Bene_Avg_Risk_Scre	393	3.152%

Tableau 4 : Pourcentage des valeurs aberrantes

Afin de visualiser la distribution des données, il faut limiter l'effet des valeurs aberrantes :

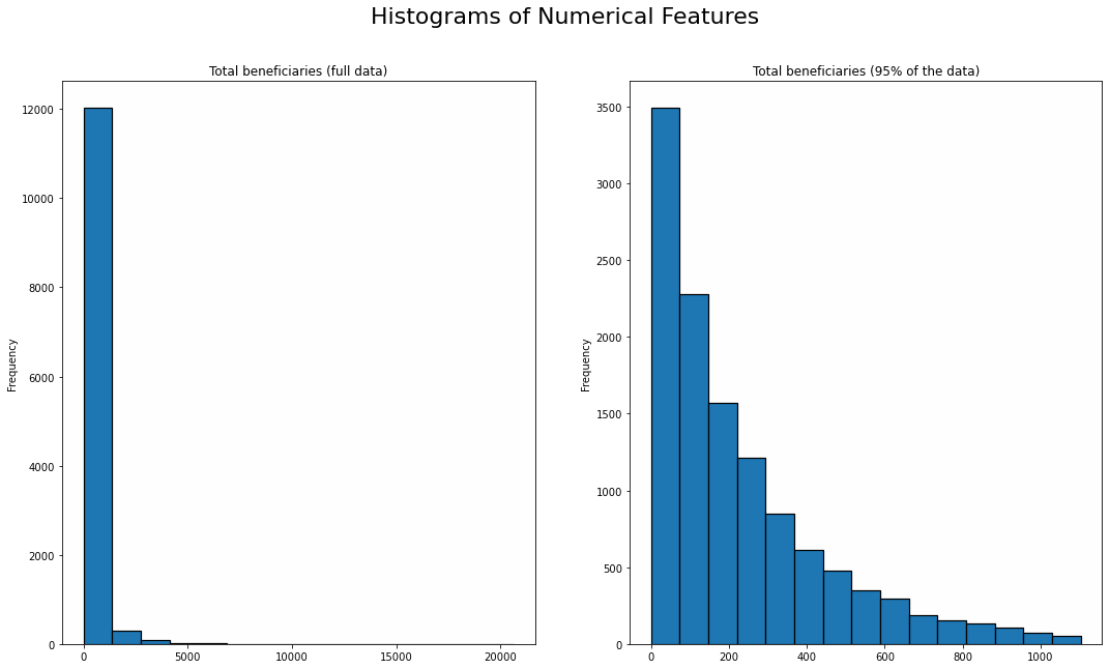


Figure 26 : Effet des valeurs aberrantes

Seulement 95% des données sont utilisés pour la visualisation des variables numériques afin de limiter cet effet.

b. Histogramme

Une distribution de fréquences montre la fréquence d'apparition de chaque valeur différente dans un ensemble de données, l'histogramme est le graphique le plus utilisé pour représenter les distributions de fréquences.

La distribution des valeurs numériques dans notre base de données (95% des données) :

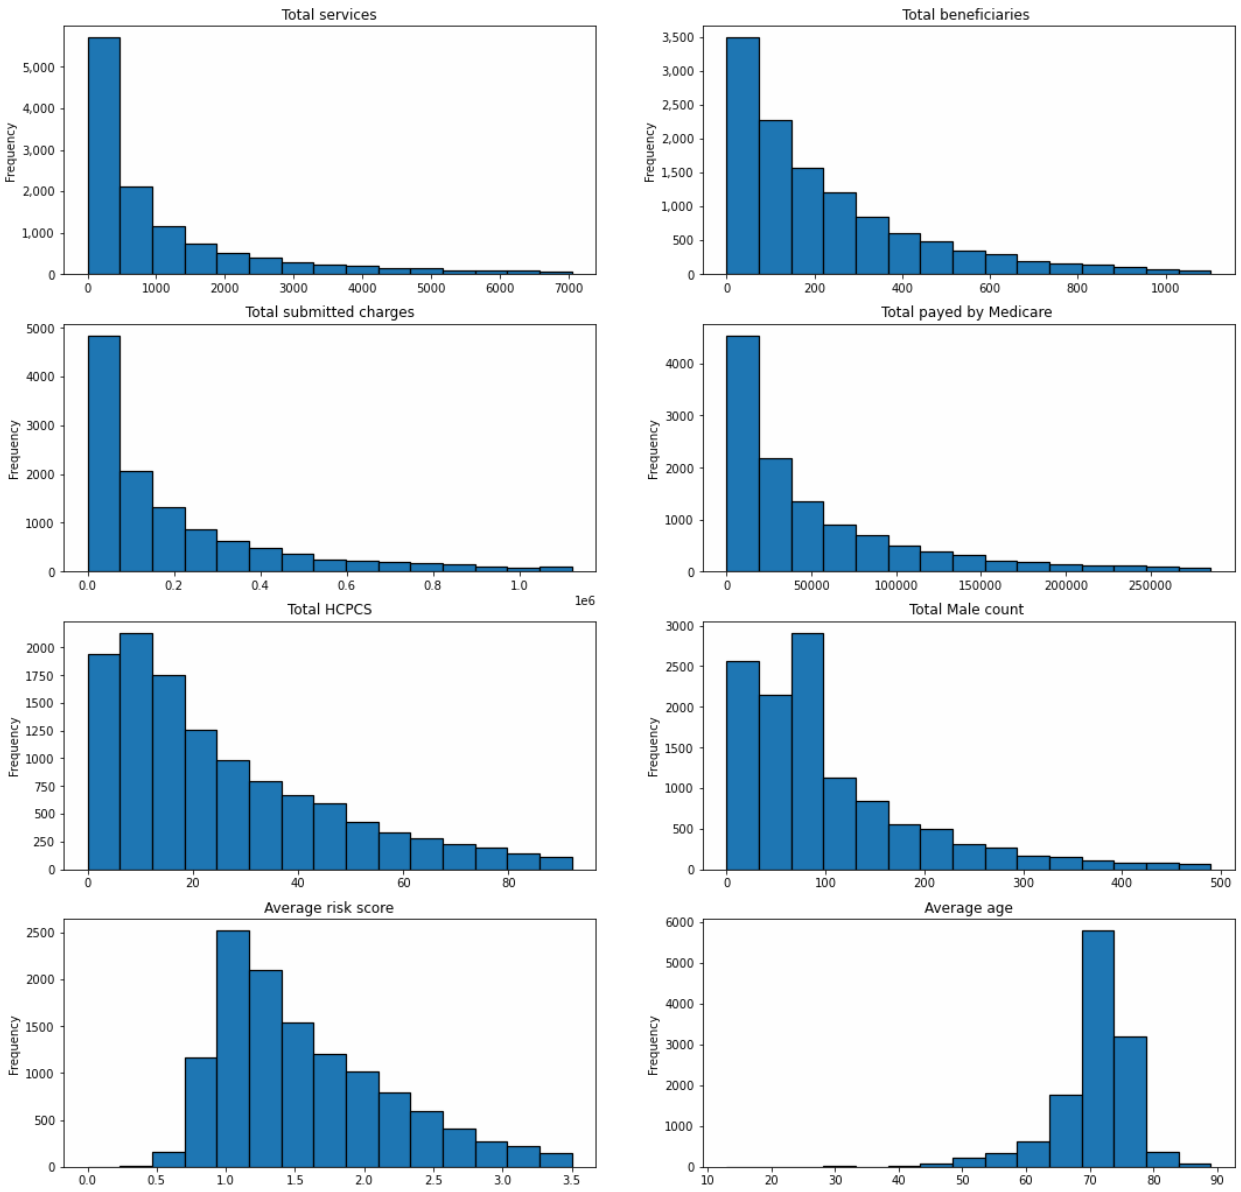


Figure 27 : Distribution des variables numériques

Les histogrammes de toutes les variables numériques sont asymétriques vers droite (sauf l'âge moyen des patients), c'est-à-dire, les petites valeurs sont les plus fréquentes dans notre jeu de données. Pour l'âge moyen, la majorité des valeurs est concentrée entre 65 et 80, ce qui est logique puisque Medicare couvre principalement les personnes âgées de 65 ans ou plus.

B. Variables catégorielles

Notre base de données finale comporte 5 variables catégorielles :

- **Rndrng_Prvdr_Gndr** : sexe d'un praticien.
- **Year** : année correspondante.

- **Rndrng_Prvdr_Type** : spécialité d'un praticien.
- **Rndrng_Prvdr_State_Abrvtn** : état dans lequel le praticien est situé.
- **Fraud** : étiquette.

a. Distribution du sexe

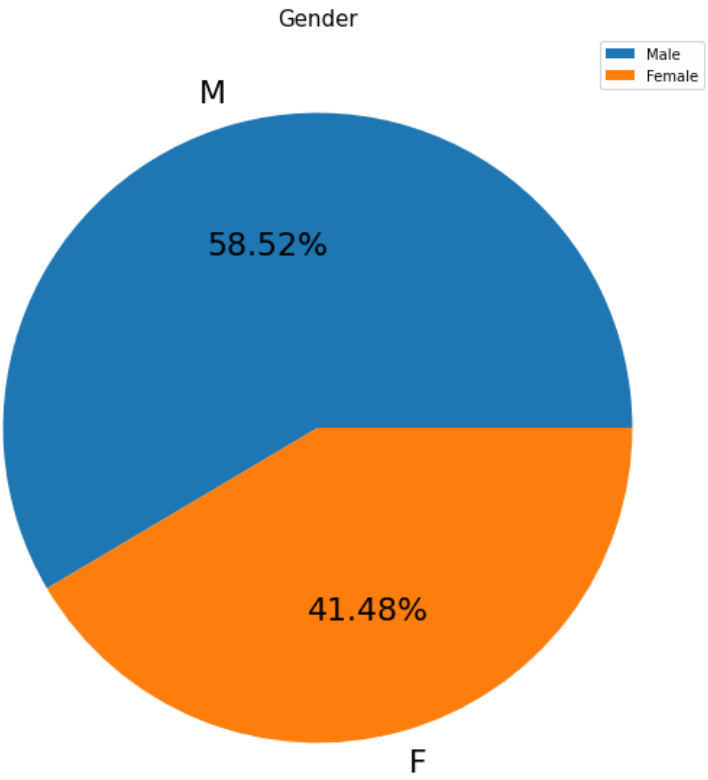


Figure 28 : Sexe des praticiens

Les praticiens masculins sont plus représentés (58.52%) dans la base de données que les praticiens de sexe féminin (41.48%).

b. Distribution des années

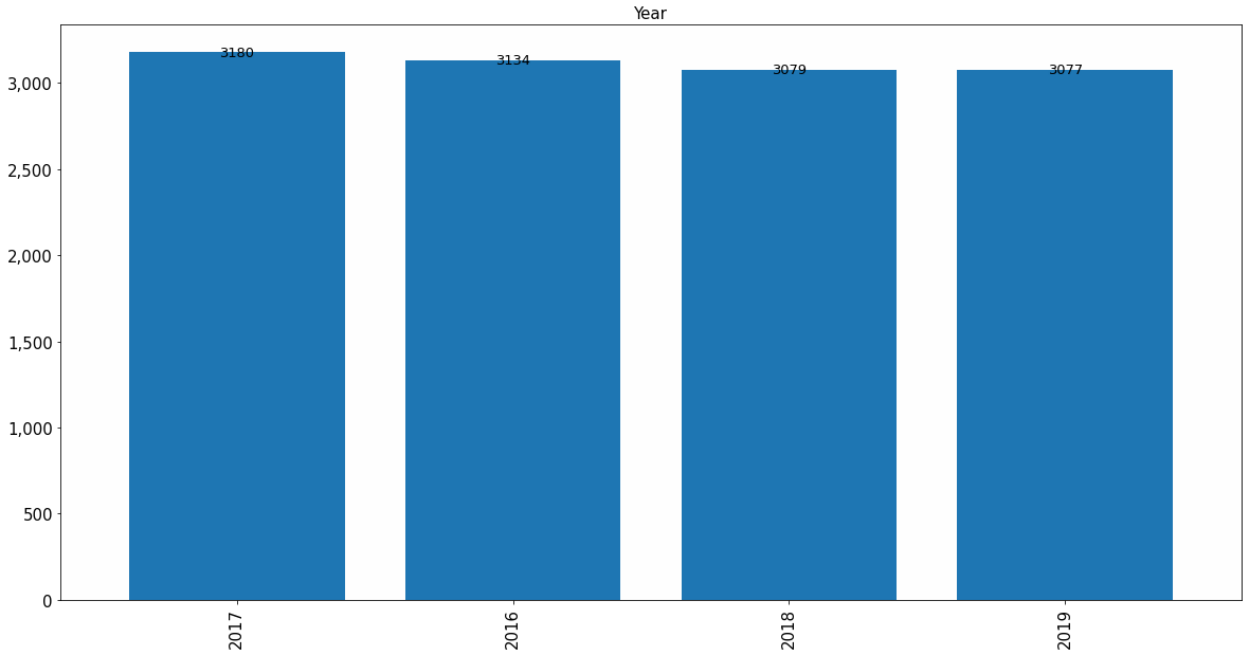


Figure 29 : Distribution des années

Le graphique ci-dessus montre que la quantité de données disponibles au fil des ans est restée relativement stable.

c. Distribution des spécialités et des états

La base de données finale contient 80 spécialités et 57 états,comme il est difficile de visualiser toutes ces valeurs, les tableaux suivants présentent les 10 spécialités et état les plus fréquentes respectivement :

Spécialité	Pourcentage
Nurse Practitioner	10.609%
Internal Medicine	10.192%
Family Practice	8.308%
Physician Assistant	6.832%
Physical Therapist in Private Practice	4.667%
Emergency Medicine	4.330%
Certified Registered Nurse Anesthetist (CRNA)	3.841%

Anesthesiology	3.801%
Chiropractic	3.761%
Obstetrics & Gynecology	3.031%

Tableau 5 : Spécialités les plus fréquentes

Etat	Pourcentage
California	8.156%
New York	7.618%
Florida	6.664%
Texas	6.415%
Pennsylvania	4.956%
Illinois	4.018%
Ohio	3.873%
Michigan	3.553%
North Carolina	3.272%
New Jersey	3.103%

Tableau 6 : Etats les plus fréquents

4.5.3 Analyse bivarié

La variable cible dans notre ensemble de données est l'étiquette de fraude, l'analyse bivariée consiste à étudier les relations entre la variable cible et les autres variables.

A. Taux de fraude par sexe

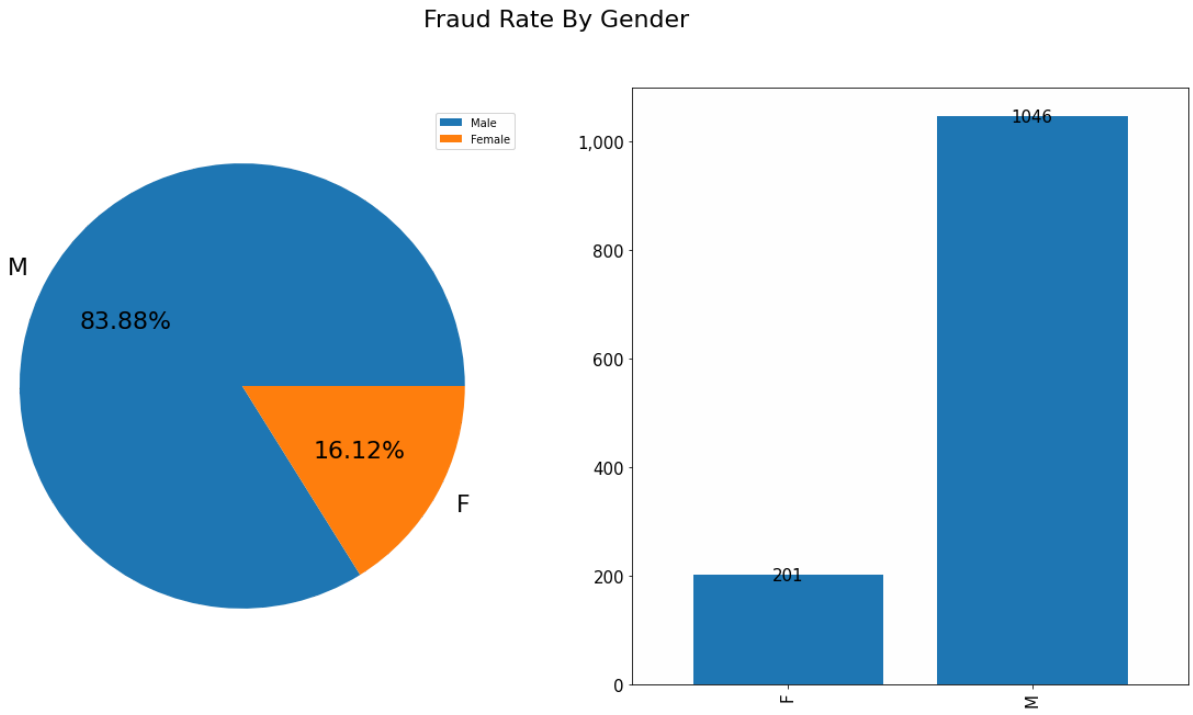


Figure 30 : Taux de fraude par sexe

D'après le graphique ci-dessus, la fraude est nettement plus susceptible d'être commise par des praticiens masculins que par des praticiennes.

B. Taux de fraude par année

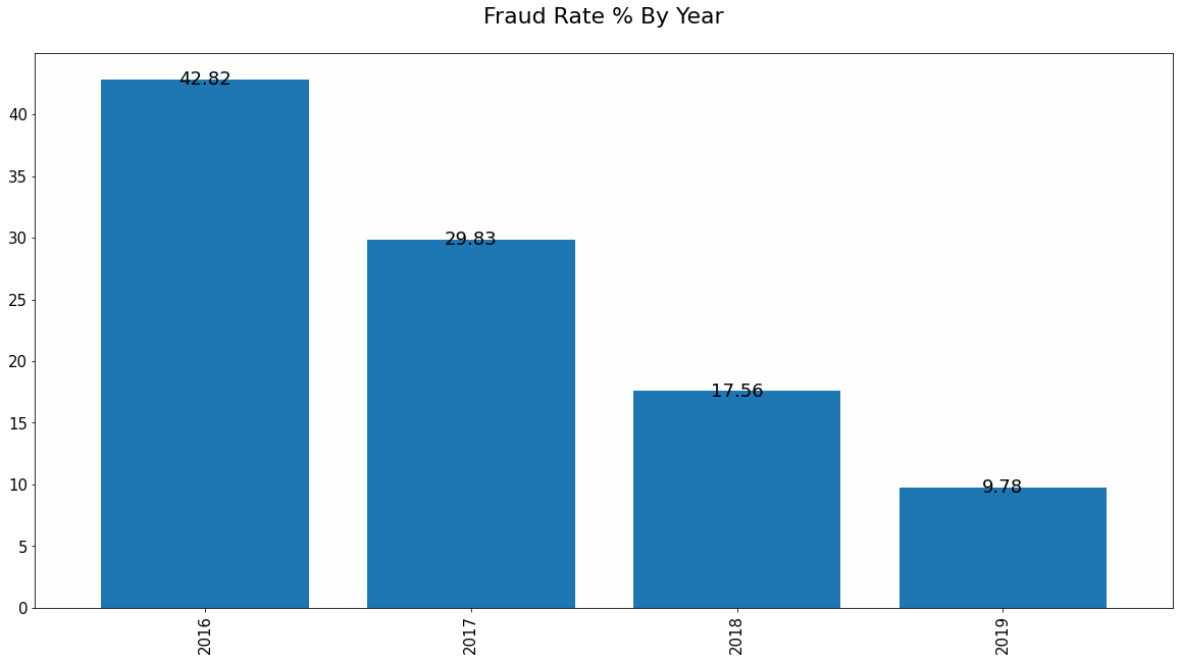


Figure 31 : Taux de fraude par année

De 42,82 % en 2016 à 9,78 % en 2019, le taux de fraude est en baisse au fil des années.

C. Taux de fraude par spécialité et état

Comme nous l'avons déjà mentionné, la base de données finale contient 80 spécialités et 57 états et il est donc difficile de visualiser toutes ces valeurs, les tableaux suivants présentent les 10 spécialités et état les plus frauduleux respectivement :

Spécialité	Pourcentage de fraude
Internal Medicine	17.402%
Family Practice	15.477%
Nurse Practitioner	5.854%
Chiropractic	5.293%
Psychiatry	5.052%
Emergency Medicine	4.170%
Podiatry	4.010%
Anesthesiology	3.929%
Obstetrics & Gynecology	3.448%
Physical Medicine and Rehabilitation	3.128%

Tableau 7 : Spécialités les plus frauduleuses

Etat	Pourcentage de fraude
Florida	12.430%
New York	10.746%
California	9.142%
Texas	7.137%
Illinois	6.095%
Miami	4.731%

Pennsylvania	3.849%
Georgia	3.528%
Ohio	3.448%
New jersey	3.047%

Tableau 8 : Etats les plus frauduleux

D. Corrélation

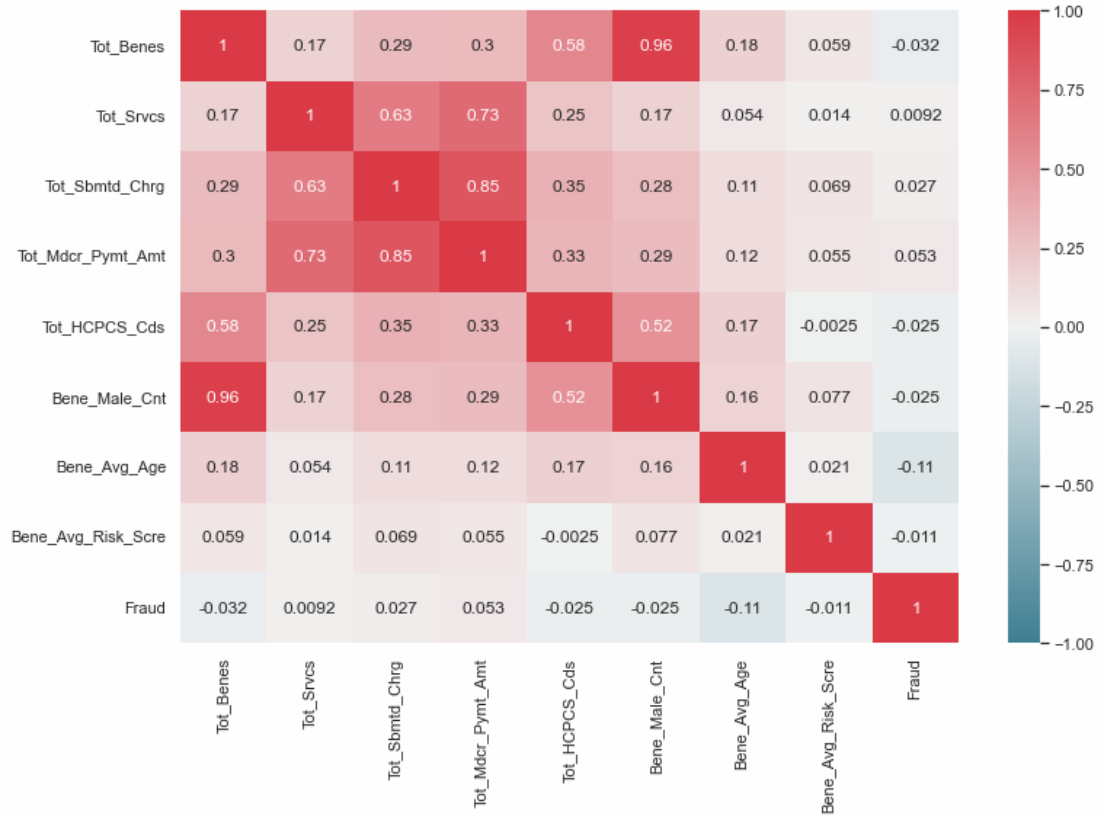


Figure 32 : Corrélation des variables

Le nombre total de patients et le nombre total de patients masculins, ainsi que le nombre total de services et le nombre total de frais soumis et remboursés par Medicare, sont fortement corrélés. Il s'agit d'une relation positive, ce qui signifie que lorsqu'une variable augmente, les autres augmentent également.

4.6 Conclusion

L'objectif de ce chapitre était de décrire la méthodologie utilisée pour la réalisation de notre projet. Nous avons commencé par présenter le cycle OSEMN, puis nous avons

présenté les outils clés de l’implémentation, enfin nous avons discuté des résultats de l'exploration des données.

5 Modélisation et résultats

5.1 Introduction

La modélisation consiste à développer et évaluer les différents algorithmes d'apprentissage afin de résoudre la problématique de départ, c'est une étape cruciale au cours d'un projet intelligence artificielle. La modélisation se compose généralement de plusieurs sous-parties, à savoir : le prétraitement, l'entrainement, l'optimisation des paramètres et finalement, l'interprétation des résultats obtenus.

5.2 Prétraitement

Le prétraitement des données est une tâche très importante qui doit intervenir avant l'entrainement des modèles, le but de cette tâche est de préparer les données brutes pour qu'elles conviennent à la formation de modèles d'intelligence artificielle.

Pour l'entrainement de notre modèle, l'année correspondante et le code NPI sont supprimés de la base de données, le but est de détecter les fraudes indépendamment de ces variables.

5.2.1 Conversion des variables catégorielles

Les variables de catégorielles doivent être transformées en valeurs numériques pour que le modèle puisse les traiter, car la majorité des modèles d'apprentissage automatique ne prennent que des variables numériques. L'encodage One-hot est l'approche la plus utilisée pour la conversion des variables catégoriques. Il crée de nouvelles colonnes (binaires), indiquant la présence de chaque valeur possible des données d'origine.

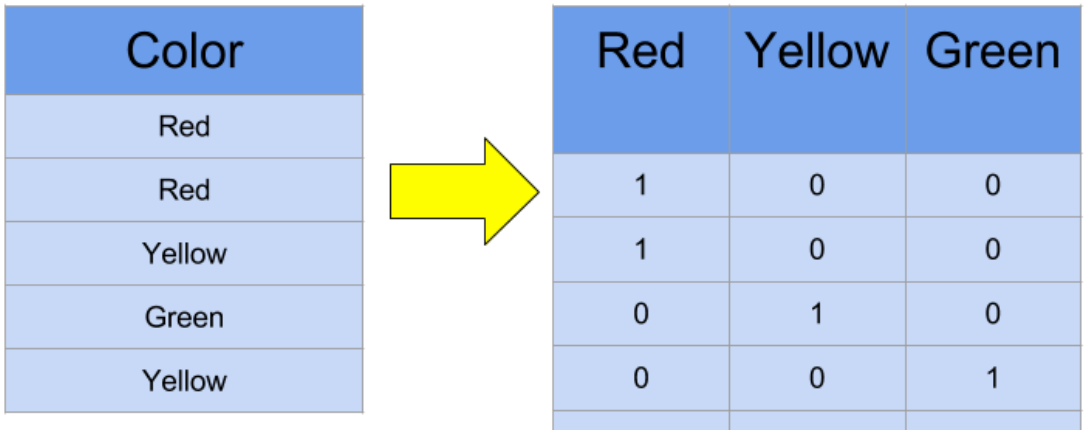


Figure 33 : One-hot encoding

5.2.2 Répartition des données

La répartition entrainement-test (*train-test split*), est une procédure de validation de modèle qui vous permet de simuler comment un modèle se comportera sur des données nouvelles ou inconnues. La procédure fonctionne de la manière suivante :

1. Vérifier si les données sont disposées dans un format acceptable pour le train-test split, ce qui consiste à séparer votre ensemble de données complet en attributs a et variable cible.
2. Diviser l'ensemble de données en deux parties : un ensemble d'entraînement et un ensemble de test. Il s'agit d'échantillonner au hasard, sans remplacement, un certain pourcentage de lignes et de les placer dans l'ensemble d'entraînement et de placer les lignes restantes dans l'ensemble de test.
3. Normalisation des données : transformations des valeurs pour qu'elles soient à une échelle similaire, ceci améliore les performances et la stabilité pendant l'entrainement du modèle.
4. Entraîner le modèle sur l'ensemble d'entraînement.
5. Tester et évaluer le modèle sur l'ensemble de test

Pour notre problème de classification, les données sont déséquilibrées. Il est donc souhaitable de diviser l'ensemble de données en ensembles d'entrainement et de test de manière à conserver les mêmes proportions d'exemples dans chaque classe que celles observées dans l'ensemble de données original, il s'agit d'une répartition **stratifiée** des données.

Conformément aux travaux effectués dans [21] et [14], 80% des données sont consacrés à l'entrainement, et les 20 % qui restent pour le test.

Subset	Percentage	Non_fraudulent	Fraudulent	Fraudulent %
Train	80.032%	8978	998	10.004%
Test	19.968%	2245	249	9.984%

Tableau 9 : Train-Test split

5.3 Validation croisée

La validation croisée (*Cross Validation*) est une méthode statistique utilisée pour estimer la performance des modèles d'apprentissage automatique. Elle est couramment utilisée dans l'apprentissage automatique appliqué pour comparer et sélectionner un modèle pour un problème de modélisation prédictive donné, car elle est facile à comprendre, facile à mettre en œuvre et donne des estimations de performances qui ont généralement un biais plus faible que les autres méthodes.

La validation croisée comporte deux étapes principales : la division des données en **k** sous-ensembles (blocs) et la permutation de l'entrainement et de la validation entre ces sous-ensembles, la technique de répartition a généralement les propriétés suivantes :

- Chaque bloc a approximativement la même taille.
- Dans chaque bloc, les données peuvent être sélectionnées de façon aléatoire ou stratifiée.

- Tous les blocs sont utilisés pour former le modèle, sauf un, qui est utilisé pour la validation.
- Ce bloc de validation doit être tourné jusqu'à ce que tous les plis soient devenus un pli de validation une fois et seulement une fois.

L'un des avantages de la validation croisée est d'observer les prédictions du modèle par rapport à toutes les instances de l'ensemble de données, elle garantit que le modèle a été testé sur l'ensemble des données sans les tester simultanément, le résultat final est la moyenne de toutes les itérations.

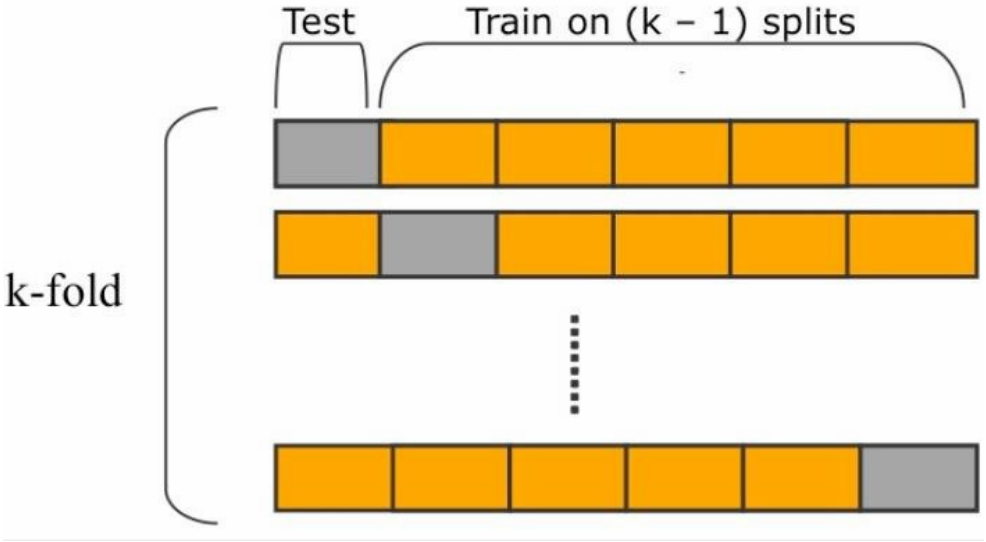


Figure 34 : Validation croisée

Dans notre cas, la validation croisée stratifiée est utilisée pour déterminer les meilleures techniques d'échantillonnage ainsi que les meilleurs hyperparamètres, l'ensemble de test défini dans la section précédente est utilisé pour l'évaluation finale du modèle. La procédure est répétée 10 fois pour réduire le biais avec k = 5 [18].

5.4 Métriques d'évaluation

Alors que la préparation des données et l'entraînement d'un modèle prédictif sont des étapes clés dans le pipeline de la science des données, il est tout aussi important de mesurer la performance de ce modèle entraîné, pour évaluer les modèles de classification, de nombreuses métriques peuvent être utilisées.

Cependant, pour traiter notre problème de classification déséquilibrée, il faut détecter la classe minoritaire avec une grande précision, pour la détection des fraudes, il est crucial de trouver tous les cas positifs réels. Un excellent classifieur devrait prédire correctement toutes instances de la classe minoritaire avec un faible taux de fausses alarmes.

5.4.1 Matrice de confusion

La matrice de confusion représente la base de nos métriques. A l'aide de la matrice de confusion, nous pouvons générer les métriques les plus courantes dans la littérature

pour estimer la performance d'un classifieur avec différentes perspectives, comme l'aire sous la courbe ROC (ROC AUC) et le score F1. Ces métriques utilisent des concepts standard, à savoir le rappel et la précision. La matrice de confusion se base sur :

- **Vrais Positifs (TP)** : Les valeurs qui étaient réellement positives et qui étaient prédites positives.
- **Faux positifs (FP)** : Les valeurs qui étaient réellement négatives mais qui ont été faussement prédites comme positives.
- **Faux négatifs (FN)** : Les valeurs qui étaient en fait positives mais qui ont été prédites à tort comme négatives.
- **Vrais négatifs (TN)** : Les valeurs qui étaient réellement négatives et qui ont été prédites négatives.

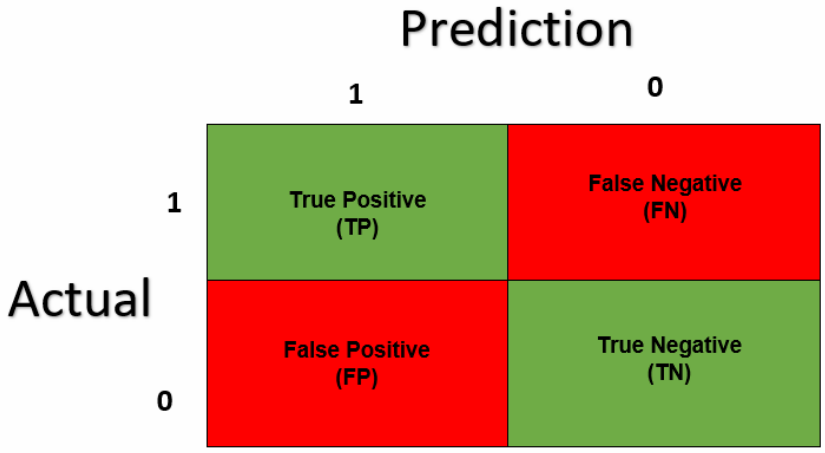


Figure 35 : Matrice de confusion

- **Le rappel** est le taux de vrais positifs, TP/(TP+FN), il s'agit du pourcentage d'instances positives correctement classées. Lorsque cette métrique est égale à un, cela signifie que nous pouvons identifier tous les cas de fraude.
- **La précision** est le pourcentage d'instances positives parmi les prédictions positives, elle est définie comme TP/(TP+FP). Une valeur élevée pour la précision signifie que notre modèle capture le comportement de fraude.

5.4.2 Evaluation des modèles

Pour l'évaluation du modèle, la validation croisée stratifiée est utilisée pour déterminer la meilleure technique d'échantillonnage et la meilleure distribution des classes, la meilleure méthode est choisie et la méthode **Grid search** est appliquée afin de trouver les meilleurs hyperparamètres. Le score final du modèle est calculé à partir de l'ensemble de test.

Grid search est une technique de paramétrage qui tente de calculer les valeurs optimales des hyperparamètres, il s'agit d'une recherche exhaustive qui est effectuée sur les valeurs spécifiques données en entrée, toutes les combinaisons de valeurs possibles sont testées afin de trouver la meilleure combinaison qui maximise un score bien déterminé.

5.5 Résultats et discussion

Dans cette section, les métriques de nos algorithmes d'intelligence artificielle sont évaluées. Nous comparons les résultats de différentes techniques d'échantillonnage pour atténuer le problème du déséquilibre des classes.

Dans un premier temps, les modèles sont entraînés avec leurs paramètres par défaut, puis la meilleure méthode est choisie pour effectuer le Grid search afin d'améliorer les performances.

5.5.1 Déséquilibre des données

Dans notre projet, le sous-échantillonnage et le suréchantillonnage aléatoires sont utilisés pour limiter les problèmes liés au déséquilibre des classes, A cause du déséquilibre important entre les étiquettes de fraude et de non-fraude, un modèle aura tendance à se concentrer sur la classe majoritaire (la classe avec la majorité des instances) et à mal représenter la classe minoritaire. Dans notre cas, les étiquettes non frauduleuses sont la classe majoritaire et les étiquettes de fraude sont la classe minoritaire, ainsi que la classe d'intérêt dans notre cas.

L'utilisation de techniques d'échantillonnage de données modifie la distribution des classes des instances d'apprentissage en augmentant la représentation de la classe minoritaire ou en diminuant la représentation de la classe majoritaire, ce qui contribue à améliorer la performance du modèle.

Il faut s'assurer que les techniques d'échantillonnage ne sont appliquées qu'aux données d'entraînement, car les données de test doivent rester intouchables parce qu'elles représentent la réalité, de plus, l'application de l'échantillonnage à l'ensemble des données, plutôt qu'aux données d'entraînement, peut entraîner un problème de fuite de données. On parle de fuite de données lorsque des informations extérieures à l'ensemble de données de formation sont utilisées pour créer le modèle, ces informations supplémentaires peuvent permettre au modèle d'apprendre ou de savoir quelque chose qu'il n'aurait pas su autrement et, par conséquent, invalider les performances estimées du mode construit et donner lieu à des performances élevées irréalistes.

Le sous-échantillonnage / sur-échantillonnage aléatoire sont détaillés dans le troisième chapitre.

Pour la présentation des résultats, la notation suivante est utilisée :

- Classe **positive** : classe minoritaire (Fraude)
- Classe **négative** : classe majoritaire (Non-fraude)

5.5.2 Random Forest

A. Modèle de base

Rappelons que la distribution des classes dans notre base de données est de :

- 90% classe négative (Non-fraude)
- 10% classe positive (Fraude)

Négative/Positive	Précision	Rappel
90/10	0.8892	0.1803

Tableau 10 : Random Forest (Modèle de base)

Nous pouvons voir que la précision du modèle est élevée (89%) alors que le rappel est très faible (18%), ce qui signifie que le modèle a tendance à détecter les praticiens non frauduleux, ce résultat est logique à cause du grand déséquilibre des données (90/10).

B. Sous-échantillonnage aléatoire

Pendant le sous-échantillonnage aléatoire, la classe majoritaire est réduite d'une manière aléatoire jusqu'à ce qu'une distribution plus équilibrée soit atteinte, quatre proportions de classe sont testées.

Négative/Positi	Précision	Rappel
80/20	0.6557	0.3359
70/30	0.4610	0.5024
60/40	0.3433	0.6581
50/50	0.2606	0.7778

Tableau 11 : Random Forest (Sous-échantillonnage aléatoire)

Il est clair, selon le tableau ci-dessus, que plus le rappel est augmenté, plus la précision est diminuée, pour la détection de fraude les faux négatifs sont les plus coûteux dans la détection des fraudes, le modèle formé avec une distribution de classe équilibrée 50/50 est le plus performant.

C. Sur-échantillonnage aléatoire

Pendant le sur-échantillonnage aléatoire, la classe majoritaire est réduite d'une manière aléatoire jusqu'à ce qu'une distribution plus équilibrée soit atteinte, quatre proportions de classe sont testées.

Négative/Positi	Précision	Rappel
80/20	0.8238	0.2529
70/30	0.7961	0.2893
60/40	0.7690	0.3050
50/50	0.7551	0.3121

Tableau 12 : Random Forest (Sur-échantillonnage aléatoire)

La précision reste relativement élevée en appliquant un sur-échantillonnage aléatoire, tandis que le rappel n'atteint pas une valeur acceptable.

D. Combinaison des deux

Une combinaison des deux techniques d'échantillonnage est essayée, dans un premier lieu, le sur-échantillonnage est appliqué, pour augmenter l'effectif de la classe positive à un certain pourcentage, ensuite un équilibre de 50/50 est atteint en appliquant le sous-échantillonnage aléatoire.

Positive percentage	Précision	Rappel
20%	0.3836	0.6224
30%	0.4969	0.4976
40%	0.6287	0.3979
50%	0.7488	0.3075

Tableau 13 : Random Forest (Sur/Sous échantillonnage)

En appliquant cette technique de combinaison, nous remarquons que les résultats sont moyens.

Pour l'algorithme Random Forest, le meilleur résultat est celui obtenu en utilisant la technique de sous-échantillonnage avec un équilibre parfait des deux classes (Fraud et Non-Fraud).

5.5.3 XGBoost

A. Modèle de base

Négative/Positi	Précision	Rappel
90/10	0.7115	0.1101

Tableau 14 : XGBoost (Modèle de base)

Le modèle classe généralement les enregistrements négatifs avec précision et néglige les enregistrements positifs lorsqu'aucune méthode d'échantillonnage n'est appliquée.

B. Sous-échantillonnage aléatoire

Négative/Positi	Précision	Rappel

80/20	0.5281	0.2300
70/30	0.3884	0.4079
60/40	0.3096	0.5868
50/50	0.2353	0.7428

Tableau 15 : XGBoost (Sous-échantillonnage aléatoire)

De même que les résultats de l'algorithme de Random Forest, lorsque le rappel augmente, la précision diminue, ceci est dû principalement au déséquilibre des classes, la distribution 50/50 donne les meilleurs résultats avec un rappel de 74,20%.

C. Sur-échantillonnage aléatoire

Négative/Positi	Précision	Rappel
80/20	0.5561	0.2154
70/30	0.4191	0.3906
60/40	0.3454	0.5604
50/50	0.2642	0.7185

Tableau 16 : XGBoost (Sur-échantillonnage aléatoire)

Les résultats obtenus en utilisant le sur-échantillonnage aléatoire sont très similaires à ceux du sous-échantillonnage aléatoire, avec un petit avantage pour le sous-échantillonnage en termes de rappel et de temps d'entrainement.

D. Combinaison des deux

Positive percentage	Précision	Rappel
20%	0.2553	0.7247
30%	0.2601	0.7228
40%	0.2630	0.7190
50%	0.2655	0.7214

Tableau 17 : XGBoost (Sur/Sous échantillonnage)

En appliquant la combinaison sous/sur-échantillonnage aléatoire, les résultats sont relativement stables pour tous les pourcentages testés.

Pour l'algorithme XGBoost, le meilleur score est celui obtenu en utilisant la technique de sous-échantillonnage avec un équilibre de 50/50.

5.5.4 Réseaux de neurones

Le choix de l'architecture du réseau de neurones est inspiré de [21],c'est une architecture qui a 2 couches cachées avec 32 neurones chacune.

A. Modèle de base

Négative/Positi	Précision	Rappel
90/10	0.13684	0.1162

Tableau 18 : Réseaux de neurones (Modèle de base)

Contrairement à Random Forest et à XGBoost, le modèle de base du réseau de neurones a des très faibles performances en termes de précision et de rappel.

B. Sous-échantillonnage aléatoire

Négative/Positi	Précision	Rappel
80/20	0.4062	0.6002
70/30	0.3384	0.6743
60/40	0.2823	0.7826
50/50	0.2411	0.8106

Tableau 19 : Réseau de neurones (Sous-échantillonnage aléatoire)

Pour le sous-échantillonnage aléatoire, les résultats du réseau de neurones ne diffèrent pas beaucoup de Random Forest ou de XGBoost, plus le rappel est amélioré, plus la précision baisse. L'équilibre parfait 50/50 nous donne le meilleur score de 81.06%.

C. Sur-échantillonnage aléatoire

Négative/Positive	Précision	Rappel
80/20	0.4858	0.4989
70/30	0.4605	0.6212

60/40	0.4513	0.6162
50/50	0.4245	0.6582

Tableau 20 : Réseau de neurones (Sur-échantillonnage aléatoire)

La précision s'améliore quand les échantillons de classes positives augmentent, cependant elle atteint un maximum de 65,82%.

D. Combinaison des deux

Positive percentage	Précision	Rappel
20%	0.3208	0.7345
30%	0.3665	0.6783
40%	0.3918	0.6834
50%	0.4249	0.6843

Tableau 21 : Réseau de neurones (Sur/Sous échantillonnage)

Lorsqu'on utilise le sous-échantillonnage et le sur-échantillonnage pour les réseaux neuronaux, le rappel commence par une valeur élevée et diminue progressivement, contrairement aux deux autres algorithmes.

5.5.5 Evaluation finale

Idéalement, nous voulons que le modèle ne signale que les praticiens frauduleux, malheureusement, la mauvaise qualité de l'ensemble de données et le déséquilibre des classes rendent cette tâche difficile, par conséquent, pour la sélection du modèle, le rappel est le score que nous avons pris en compte car pour la détection de la fraude, il est plus important de détecter le maximum de praticiens frauduleux, même si le modèle identifie certains praticiens non frauduleux comme frauduleux.

La procédure Grid search prend beaucoup de temps d'exécution, car elle teste toutes les combinaisons possibles des hyperparamètres du modèle donnés en entrée. Ainsi, seuls trois modèles sont choisis pour régler leurs paramètres en utilisant la méthode Grid search. Après avoir trouvé les paramètres optimaux, le modèle est réentraîné sur l'ensemble des données d'apprentissage en utilisant ces paramètres et évalué en utilisant l'ensemble de test déjà défini.

Étant donné que le rappel a atteint une valeur respectable (plus de 75 % de praticiens frauduleux détectés avec succès à l'aide des trois algorithmes), nous décidons de chercher des paramètres qui maximisent la précision.

Pour les trois algorithmes, la méthode qui a donné le meilleur score de rappel est le sous-échantillonnage aléatoire avec une distribution équilibrée de classes (50/50).

Algorithme	Rappel
Random Forest	0.7778
XGBoost	0.7428
Réseau de neurones	0.8106

Tableau 22 : Résultats sous-échantillonnage

Après avoir effectué le Grid search et le réentraînement des données en utilisant les paramètres optimaux, nous avons obtenu les résultats suivants :

A. Random Forest

Algorithme	Rappel	Précision
Random forest optimisé	0.8594	0.2834

Tableau 23 : Random forest optimisé

L'optimisation des paramètres nous a permis d'augmenter considérablement le rappel de 8.16% pour atteindre 85.94%, la précision a également augmenté, passant de 26.06% à 28.34%.

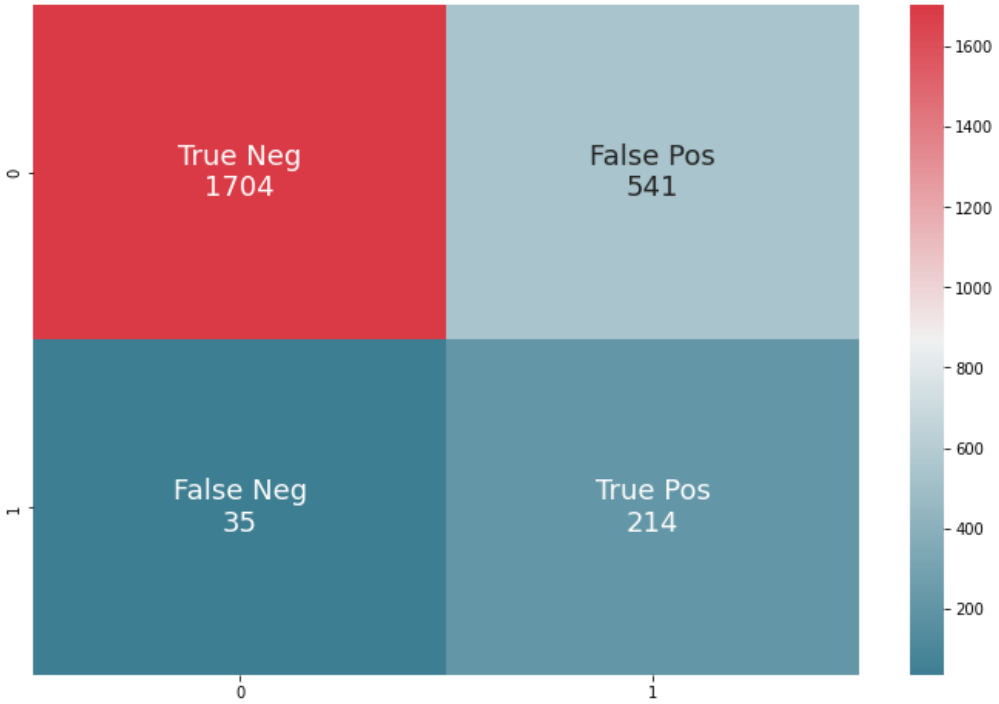


Figure 36 : Matrice de confusion Random Forest

Random Forest optimisé a détecté 755 cas frauduleux, ce qui représente environ 30 % de l'ensemble des données. L'algorithme a réussi à détecter 214 de ces cas et n'en a manqué que 35. Il est intéressant de noter que pour la classe négative (non frauduleuse), l'algorithme a réussi à classer approximativement 76% des cas. Nous pouvons dire que l'algorithme a rejeté environ 70 % des fraudeurs potentiels en ne manquant que 14 % des praticiens frauduleux.

B. XGBoost

Algorithme	Rappel	Précision
XGBoost optimisé	0.7831	0.2550

Tableau 24 : XGBoost optimisé

Le rappel a été considérablement augmenté de 4,03% pour atteindre 78,31% grâce à l'optimisation des paramètres, et la précision est passée de 23,53% à 25,49%.

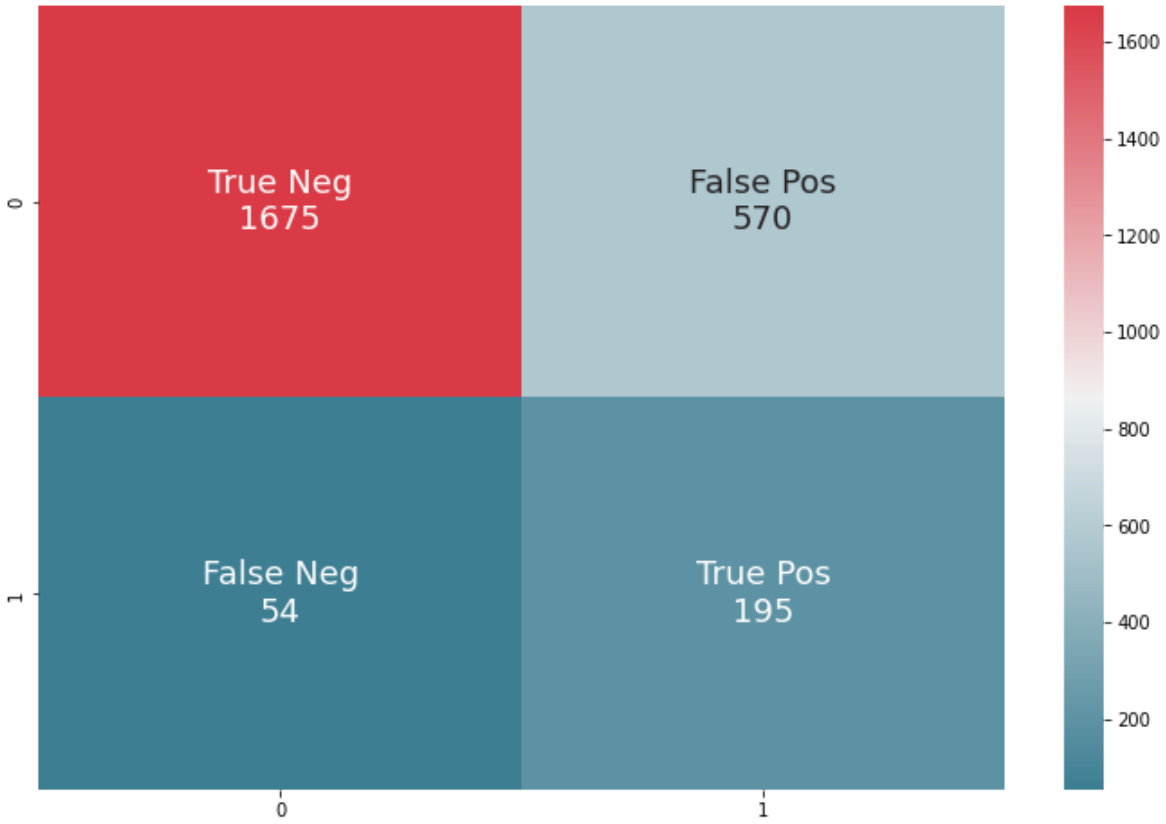


Figure 37 : Matrice de confusion XGBoost

XGBoost optimisé a détecté 755 cas frauduleux, ce qui représente environ 30% de l'ensemble des données. L'algorithme a réussi à détecter 195 de ces cas et a manqué 54. Il est intéressant de noter que pour la classe négative (non frauduleuse), l'algorithme a réussi à classer approximativement 75% des cas. Nous pouvons dire que l'algorithme

a rejeté environ 70% des fraudeurs potentiels en manquant approximativement 22% des praticiens frauduleux.

C. Réseaux de neurones

Algorithme	Rappel	Précision
Réseau de neurones optimisé	0.9076	0.2780

Tableau 25 : Réseau de neurones optimisé

Grâce à l'optimisation des paramètres, le rappel a augmenté de manière significative, de 9,7% pour atteindre 90,76%, tandis que la précision est passée de 24,11% à 25,49%.

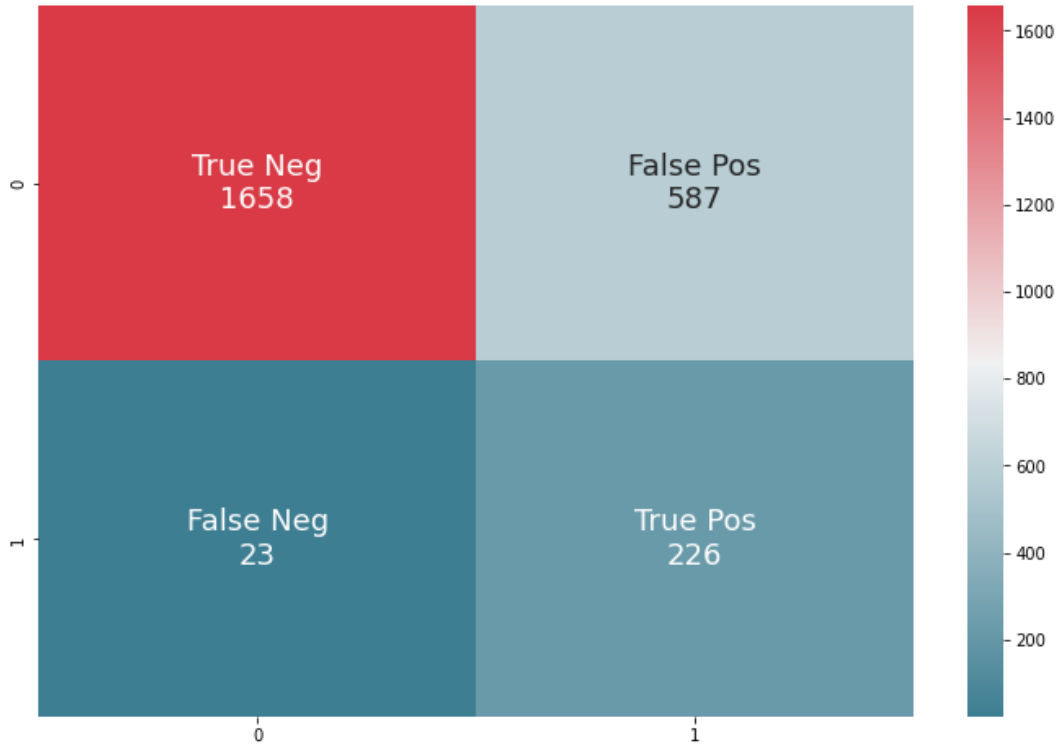


Tableau 26 : Matrice de confusion réseaux de neurones

Le réseau de neurones optimisé a détecté 813 cas frauduleux, ce qui représente environ 32% de l'ensemble des données. L'algorithme a réussi à détecter 214 de ces cas et n'en a manqué que 35. Il est intéressant de noter que pour la classe négative (non frauduleuse), l'algorithme a réussi à classer approximativement 76% des cas. Nous pouvons dire que l'algorithme a rejeté environ 70% des fraudeurs potentiels en manquant approximativement 22% des praticiens frauduleux.

Le tableau suivant résume les performances des trois algorithmes après l'optimisation des paramètres :

Algorithme	Rappel	Précision
Random Forest optimisé	0.8594	0.2834
XGBoost optimisé	0.7831	0.2550
Réseau de neurones optimisé	0.9076	0.2780

Tableau 27 : Performances des algorithmes optimisés

5.6 Conclusion

Ce dernier chapitre couvre la phase de modélisation. La préparation des données est la première étape, et après avoir testé plusieurs techniques d'échantillonnage pour chaque algorithme, la technique optimale est sélectionnée pour optimiser les paramètres du modèle afin d'améliorer les performances globales du modèle.

Conclusion générale et perspectives

Le développement de solutions basées sur l'intelligence artificielle pour lutter efficacement contre la fraude à l'assurance maladie est l'objectif de notre projet de fin d'études, qui a été réalisé au sein de l'organisation ******.

Chaque phase joue un rôle important dans la réalisation de ce projet, de l'état de l'art à la collecte passant par la préparation des données jusqu'à l'entraînement des algorithmes.

Ce stage de fin d'études m'a donné l'opportunité de bien parfaire mes acquis théoriques et pratiques, de s'adapter à travailler en harmonie dans une équipe et apprendre à s'autoformer, de plus il m'a permis d'acquérir une culture de bonnes pratiques.

Comme perspective, l'ingénierie des fonctionnalités peut être réalisée avec l'aide des experts en assurance, leur expertise sera certainement utile pour ajouter ou créer de nouvelles variables, autres que celles avec lesquelles nous avons travaillé, qui permettent d'améliorer les performances du modèle, notamment du point de vue de la précision (minimiser le taux de faux positifs), cela rendrait la lutte contre la fraude plus efficace, ce qui réduirait les pertes des compagnies d'assurance causées par les activités frauduleuses.

Bibliographie

[1] «Moroccan Foundation for Advanced Science, Innovation and Research,» [En ligne]. Available: https://www.mascir.com.

[2] «MASciR : Vocation, Vision et Mission,» [En ligne]. Available: https://www.mascir.com/mascir/vocation-vision-et-mission/.

[3] «MASciR : Partenariats & collaborations,» [En ligne]. Available: https://www.mascir.com/mascir/partenariats-collaborations/.

[4] «Insurance europe : Fraud prevention,» [En ligne]. Available: https://www.insuranceeurope.eu/priorities/23/fraud-prevention.

[5] «Lutte contre la fraude et actions de contrôle : le bilan en 2018,» [En ligne]. Available: https://assurance-maladie.ameli.fr/presse/2019-10-01-dp-controles-fraudes.

[6] «Fraud Statistics,» [En ligne]. Available: https://www.bcbsm.com/health-care-fraud/fraud-statistics.html.

[7] «Assurance maladie : la fraude ne faiblit pas !,» [En ligne]. Available: https://www.lavieeco.com/economie/assurance-maladie-la-fraude-ne-faiblit-pas/.

[8] D. a. W. J. James, «Gantt Charts: A Centenary Appreciation,» 03 2000.

[9] M. A. M. A. Z. Aisha Abdallah, «Fraud detection system: A survey,» *Journal of Network and Computer Applications,* vol. 68, pp. 90-113, 2016.

[10] R. &. K. T. &. S. N. Bauder, «A survey on the state of healthcare upcoding fraud analysis and detection.,» 2017.

[11] «Medicare Provider Utilization and Payment Data: Physician and Other Practitioners,» [En ligne]. Available: https://www.cms.gov/Research-Statistics-Data-and-Systems/Statistics-Trends-and-Reports/Medicare-Provider-Charge-Data/Physician-and-Other-Supplier.

[12] R. A. a. K. T. M. Bauder, «A Novel Method for Fraudulent Medicare Claims Detection from Expected Payment Deviations,» *IEEE 17th International Conference on Information Reuse and Integration (IRI),* pp. 11-19, 2016.

[13] «Understanding AUC - ROC Curve,» [En ligne]. Available: https://towardsdatascience.com/understanding-auc-roc-curve-68b2303cc9c5.

[14] I. a. K. E. a. R.-C. R. a. Z. A. a. K. R. a. S. M. a. B. E. Fursov, «IEEE Access,» *Sequence Embeddings Help Detect Insurance Fraud,* vol. 10, pp. 32060-32074, 2017.

[15] «LEIE Downloadable Databases,» [En ligne]. Available: https://oig.hhs.gov/exclusions/exclusions_list.asp.

[16] «Local Outlier Factor (LOF) — Algorithm for outlier identification,» [En ligne]. Available: https://towardsdatascience.com/local-outlier-factor-lof-algorithm-for-outlier-identification-8efb887d9843.

[17] R. a. d. R. R. a. K. T. Bauder, «Identifying Medicare Provider Fraud with Unsupervised Machine Learning,» *IEEE International Conference on Information Reuse and Integration (IRI),* pp. 285-292, 2018.

[18] R. a. K. T. Bauder, «Medicare Fraud Detection Using Random Forest with Class Imbalanced Big Data,» *IEEE International Conference on Information Reuse and Integration (IRI),* pp. 80-87, 2018.

[19] «Understanding Random Forest,» [En ligne]. Available: https://towardsdatascience.com/understanding-random-forest-58381e0602d2.

[20] «Random Oversampling and Undersampling for Imbalanced Classification,» [En ligne]. Available: https://machinelearningmastery.com/random-oversampling-and-undersampling-for-imbalanced-classification/.

[21] J. M. a. K. T. M. Johnson, «Deep Learning and Data Sampling with Imbalanced Big Data,» *IEEE 20th International Conference on Information Reuse and Integration for Data Science (IRI),* pp. 175-183, 2019.

[22] R. a. M. S. a. B. P. K. Gupta, «{A Comparative Study of Using Various Machine Learning and Deep Learning-Based Fraud Detection Models For Universal Health Coverage Schemes,» *International Journal of Engineering Trends and Technology,* vol. 69, pp. 96-102, 2021.

[23] J. a. K. T. M. Hancock, «Medicare Fraud Detection using CatBoost,» *IEEE 21st International Conference on Information Reuse and Integration for Data Science (IRI),* pp. 97-103, 2020.

[24] Y. M. Haibo He, chez *Imbalanced Learning: Foundations, Algorithms, and Applications*, Wiley-IEEE Press, 2013, p. 45.

[25] P. B. a. L. T. a. R. P. Ribeiro, «A Survey of Predictive Modelling under Imbalanced Distributions,» *CoRR,* 2015.

[26] H. R. A. M.-B. B. M. M. G. B. N. M. &. A. M. Joudaki, «Using data mining to detect health care fraud and abuse: a review of literature,» *Global journal of health science,* pp. 194-202, 2014.

[27] L. Breiman, «Random Forests,» *Machine Learning,* p. 5–32, 2001.

[28] J. Quinlan, «Induction of decision trees,» *Mach Learn,* pp. 81-106, 1986.

[29] J. H. Friedman, «Greedy function approximation: A gradient boosting machine,» *The Annals of Statistics,* vol. 29, n° %15, pp. 1186-1232, 2001.

[30] «Distributed (Deep) Machine Learning Community,» [En ligne]. Available: https://github.com/dmlc.

[31] F. Rosenblatt, «The perceptron: a probabilistic model for information storage and organization in the brain.,» *Psychological review,* vol. 65 6, pp. 386-408, 1958.

[32] M.-C. a. B. V. a. P.-P. L. a. M. N. Popescu, «Multilayer perceptron and neural networks,» *WSEAS Transactions on Circuits and Systems,* vol. 8, p. 579 – 588, 2009.

[33] «What Is Medicare?,» [En ligne]. Available: https://www.investopedia.com/terms/m/medicare.asp.

[34] «What is OIG?,» [En ligne]. Available: https://www.choicescreening.com/blog/what-is-oig.

[35] M. K. T. &. B. Herland, «Big Data fraud detection using multiple medicare data sources,» *Journal of Big Data,* p. 29, 2018.

[36] «Hierarchical Condition Category Coding,» [En ligne]. Available: https://www.aafp.org/family-physician/practice-and-career/getting-paid/coding/hierarchical-condition-category.html.

[37] «A Taxonomy of Data Science,» [En ligne]. Available: https://sites.google.com/a/isim.net.in/datascience_isim/taxonomy#:~:text=All%20of%20these%20are%20partially,%2C%20which%20rhymes%20with%20possum)..

[38] «The Chi squared tests,» [En ligne]. Available: https://www.bmj.com/about-

bmj/resources-readers/publications/statistics-square-one/8-chi-squared-tests.

[39] «Two-Sample Kolmogorov-Smirnov Test,» [En ligne]. Available: real-statistics.com/non-parametric-tests/goodness-of-fit-tests/two-sample-kolmogorov-smirnov-test/.